

Эконометрика

Лекция 4. Модели временных рядов: ACF, PACF, AR, MA, ARMA, ARIMA, SARIMA

Конспект

Краткое содержание лекции:

- Лаговый оператор L и формальная запись моделей через AR/МА-полиномы.
- Автокорреляционная функция (ACF) и частная автокорреляционная функция (PACF).
- Авторегрессионные модели $AR(p)$, уравнения Юла–Уокера.
- Скользящие средние $MA(q)$ и обратимость.
- Смешанные модели $ARMA(p, q)$: стационарность, среднее, представление $MA(\infty)$.
- Нестационарные процессы: TS vs DS, интегрированные процессы $I(d)$.
- Расширения: ARIMA, ARIMAX, ARFIMA, SARIMA.

Содержание

1	Лаговый оператор и формальная запись моделей	3
1.1	Определение лагового оператора	3
1.2	Запись модели ARMA через лаговый оператор	3
1.3	AR- и МА-полиномы	4
2	ACF и PACF: различение AR и MA процессов	5
2.1	Автокорреляционная функция (ACF)	5
2.2	Частная автокорреляционная функция (PACF)	5
3	Авторегрессионные процессы AR(p)	5
3.1	Определение модели AR(p)	6
3.2	Поведение PACF для AR(p)	6

3.3	Уравнения Юла–Уокера	6
4	Процессы скользящего среднего $MA(q)$	7
4.1	Определение $MA(q)$	7
4.2	Обратимость MA -процесса	7
4.3	Проблема неидентифицируемости	8
4.4	Когда необратимость возникает «сама собой»	8
5	Смешанные модели $ARMA(p,q)$	8
5.1	Условие стационарности через корни AR -полинома	8
5.2	Среднее значение стационарного $ARMA$	10
5.3	Представление стационарного $ARMA$ как $MA(\infty)$	10
5.4	Иллюстрации: типичные траектории и корреллограммы	11
5.5	Идентификация модели по ACF и $PACF$	11
6	Нестационарные процессы	12
6.1	Trend Stationary (TS) процессы	12
6.2	Difference Stationary (DS) процессы	13
6.3	Интегрированные процессы $I(d)$	13
7	$ARIMA(p,d,q)$	14
8	$ARIMAX(p,d,q)$	14
9	$ARFIMA(p,d,q)$	14
10	$SARIMA$: учёт сезонности	15
11	Итоговая схема классификации моделей	16

1. Лаговый оператор и формальная запись моделей

Прежде чем разбирать конкретные модели, введём удобный технический инструмент — лаговый оператор, который «отматывает время на шаг назад». Он позволит компактно записывать любые модели семейства ARMA и формулировать условия стационарности через корни многочленов.

1.1. Определение лагового оператора

Лаговый оператор L

Лаговый оператор L — это формальный оператор, действующий на временной ряд по правилу:

$$L(x_t) \stackrel{\text{def}}{=} x_{t-1}.$$

Применяя его дважды:

$$L^2(x_t) = L(L(x_t)) = L(x_{t-1}) = x_{t-2}.$$

По индукции:

$$L^k(x_t) = x_{t-k}, \quad k \in \mathbb{N}.$$

Формально полагают $L^0(x_t) = x_t$ — оператор «без сдвига».

Замечание

Оператор L обладает свойствами обычного «множителя»: его можно складывать ($L + L^2$), умножать ($L \cdot L^2 = L^3$), раскладывать на множители — это и делает его очень удобным для алгебраических манипуляций с моделями временных рядов. Для константы: $L(c) = c$.

1.2. Запись модели ARMA через лаговый оператор

Начнём сразу с общего вида модели ARMA(p, q):

$$x_t = \mu + \underbrace{\sum_{j=1}^p \phi_j x_{t-j}}_{\text{AR-часть}} + u_t + \underbrace{\sum_{s=1}^q \theta_s u_{t-s}}_{\text{MA-часть}}, \quad u_t \sim \text{WN}(0, \sigma_u^2), \quad \phi_p, \theta_q \neq 0. \quad (1)$$

Интерпретация коэффициентов:

- μ — константа, связана со средним уровнем ряда.
- ϕ_j — коэффициенты AR-части: насколько сильно прошлые значения x_{t-j} влияют на текущее значение.
- θ_s — коэффициенты MA-части: насколько долго отголоски прошлых шоков u_{t-s} остаются в ряду.
- u_t — текущий внешний шок (белый шум).

Замечание

Коэффициенты модели ARMA в общем случае не имеют экономической интерпретации — это просто параметры, которые наилучшим образом описывают динамику ряда. Это отличает ARMA-модели от структурных эконометрических моделей.

Перепишем (1) с использованием лагового оператора. Так как $\sum \phi_j x_{t-j} = \sum \phi_j L^j x_t$ и $\sum \theta_s u_{t-s} = \sum \theta_s L^s u_t$:

$$x_t = \mu + \sum_{j=1}^p \phi_j L^j x_t + u_t + \sum_{s=1}^q \theta_s L^s u_t.$$

Перенесём всё, что содержит x_t , в левую часть и вынесем x_t за скобку:

$$\left(1 - \sum_{j=1}^p \phi_j L^j\right) x_t = \mu + \left(1 + \sum_{s=1}^q \theta_s L^s\right) u_t.$$

1.3. AR- и MA-полиномы

Теперь введём два многочлена степени p и q соответственно — это характеристические многочлены модели:

$$\begin{aligned}\phi(z) &= 1 - \sum_{j=1}^p \phi_j z^j = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p, \\ \theta(z) &= 1 + \sum_{s=1}^q \theta_s z^s = 1 + \theta_1 z + \theta_2 z^2 + \dots + \theta_q z^q.\end{aligned}$$

Тогда модель ARMA записывается в максимально компактной форме:

$$\boxed{\phi(L) x_t = \mu + \theta(L) u_t.}$$

AR- и MA-многочлены

- Многочлен $\phi(z)$ называется авторегрессионным многочленом.
- Выражение $\phi(L) x_t$ называется AR-частью модели ARMA.
- Выражение $\theta(L) u_t$ называется MA-частью (от Moving Average — скользящего среднего).

Многочлен $\phi(z)$ имеет p корней (с учётом кратности), а $\theta(z)$ — q корней.

Замечание

Зачем такая абстракция? AR-полином действует на сам ряд x_t , MA-полином — на шумы u_t . Условия стационарности и обратимости формулируются именно через корни этих многочленов — мы увидим это уже в следующих разделах.

2. ACF и PACF: различие AR и MA процессов

2.1. Автокорреляционная функция (ACF)

Определение ACF

Автокорреляционная функция (Autocorrelation Function) стационарного процесса $\{y_t\}$ — это функция, сопоставляющая лагу k корреляцию между значениями ряда, отстоящими друг от друга на k периодов:

$$\rho_k = \text{corr}(y_t, y_{t-k}) = \frac{\text{Cov}(y_t, y_{t-k})}{\sqrt{\text{Var}(y_t) \text{Var}(y_{t-k})}} = \frac{\gamma_k}{\gamma_0}$$

где $\gamma_k = \text{Cov}(y_t, y_{t-k})$ — автоковариация лага k .

ACF измеряет «общую» силу связи между y_t и y_{t-k} — включая косвенные связи через промежуточные значения $y_{t-1}, \dots, y_{t-k+1}$.

2.2. Частная автокорреляционная функция (PACF)

Определение PACF

Частная автокорреляционная функция (Partial Autocorrelation Function) — это корреляция между y_t и y_{t-k} при условии устранения влияния промежуточных значений:

$$\varphi_{kk} = \text{corr}(y_t, y_{t-k} \mid y_{t-1}, y_{t-2}, \dots, y_{t-k+1})$$

Практическое определение через регрессию. Коэффициент φ_{kk} — это последний коэффициент регрессии:

$$y_t = \varphi_{k1}y_{t-1} + \varphi_{k2}y_{t-2} + \dots + \varphi_{kk}y_{t-k} + u_t.$$

То есть для каждого k строится отдельная регрессия порядка k , и из неё берётся только коэффициент при самом дальнем лаге.

Замечание

Зачем нужны обе функции? ACF и PACF — это диагностические инструменты для идентификации модели:

- ACF «обрезается» на лаге $q \Rightarrow$ процесс похож на $\text{MA}(q)$.
- PACF «обрезается» на лаге $p \Rightarrow$ процесс похож на $\text{AR}(p)$.

3. Авторегрессионные процессы AR(p)

3.1. Определение модели AR(p)

Процесс AR(p)

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \varepsilon_t$$

где $\varepsilon_t \sim \text{WN}(0, \sigma^2)$ — белый шум.

3.2. Поведение PACF для AR(p)

Рассмотрим, что произойдёт, если мы оценим регрессию с $k > p$ лагами:

$$y_t = \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \underbrace{\alpha_{p+1} y_{t-p-1}}_{=0} + \dots + \underbrace{\alpha_k y_{t-k}}_{=0} + \varepsilon_t.$$

Истинные коэффициенты при «лишних» лагах равны нулю — ведь процесс зависит только от p предыдущих значений. Следовательно:

Ключевое свойство AR(p)

Для процесса AR(p):

$$\varphi_{pp} = \alpha_p, \quad \text{PACF}(k) = \varphi_{kk} = 0 \quad \forall k > p.$$

Вывод: PACF процесса AR(p) обрывается после лага p . Это и есть способ определить порядок p по графику PACF.

3.3. Уравнения Юла–Уокера

Эти уравнения связывают коэффициенты φ_{ki} из регрессии PACF с автокорреляциями ρ_k . Получаются они умножением AR-уравнения на y_{t-j} и взятием матожидания.

Для регрессии длины k :

$$\begin{cases} \rho_1 = \varphi_{k1}\rho_0 + \varphi_{k2}\rho_1 + \dots + \varphi_{kk}\rho_{k-1}, \\ \rho_2 = \varphi_{k1}\rho_1 + \varphi_{k2}\rho_0 + \dots + \varphi_{kk}\rho_{k-2}, \\ \vdots \\ \rho_k = \varphi_{k1}\rho_{k-1} + \varphi_{k2}\rho_{k-2} + \dots + \varphi_{kk}\rho_0. \end{cases}$$

(напомним, $\rho_0 = 1$).

По правилу Крамера решение для φ_{kk} имеет вид:

$$\varphi_{kk} = \frac{\begin{vmatrix} \rho_0 & \rho_1 & \cdots & \rho_{k-2} & \rho_1 \\ \rho_1 & \rho_0 & \cdots & \rho_{k-3} & \rho_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & \rho_1 & \rho_k \end{vmatrix}}{\begin{vmatrix} \rho_0 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & \rho_0 & \cdots & \rho_{k-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & \rho_0 \end{vmatrix}}$$

Рекуррентная форма для AR(p)

Для самого процесса $AR(p)$ автокорреляции удовлетворяют тому же рекуррентному соотношению, что и сам процесс:

$$\rho_{p+1} = \alpha_1 \rho_p + \alpha_2 \rho_{p-1} + \dots + \alpha_p \rho_1.$$

В общем виде: $\rho_k = \alpha_1 \rho_{k-1} + \dots + \alpha_p \rho_{k-p}$ при $k \geq p$. Поэтому ACF у $AR(p)$ не обрывается, а плавно затухает (экспоненциально или по синусоиде).

4. Процессы скользящего среднего MA(q)

4.1. Определение MA(q)

Процесс MA(q)

$$y_t = \varepsilon_t + \beta_1 \varepsilon_{t-1} + \beta_2 \varepsilon_{t-2} + \dots + \beta_q \varepsilon_{t-q}$$

где $\varepsilon_t \sim WN(0, \sigma^2)$.

Используя лаговый оператор L (где $Ly_t = y_{t-1}$), запишем:

$$y_t = (1 + \beta_1 L + \beta_2 L^2 + \dots + \beta_q L^q) \varepsilon_t.$$

Свойство ACF: У процесса $MA(q)$ автокорреляции $\rho_k = 0$ при всех $k > q$ — то есть ACF обрывается на лаге q .

4.2. Обратимость MA-процесса

Это центральное понятие — оно отвечает на вопрос «можно ли по наблюдаемому ряду y_t восстановить ненаблюдаемые шоки ε_t ?».

Введём характеристический многочлен MA-полинома и его корни $\lambda_1, \dots, \lambda_q$:

$$\lambda^q + \beta_1 \lambda^{q-1} + \dots + \beta_q = 0 \implies \lambda_1, \lambda_2, \dots, \lambda_q.$$

Тогда MA-полином факторизуется:

$$y_t = (1 - \lambda_1 L)(1 - \lambda_2 L) \dots (1 - \lambda_q L) \varepsilon_t.$$

Условие обратимости

Если $|\lambda_j| < 1$ для всех $j = 1, \dots, q$, то процесс называется обратимым, и его можно представить как $AR(\infty)$:

$$(1 - \lambda_1 L)^{-1} (1 - \lambda_2 L)^{-1} \dots (1 - \lambda_q L)^{-1} y_t = \varepsilon_t,$$

то есть

$$(1 - \alpha_1 L - \alpha_2 L^2 - \dots) y_t = \varepsilon_t \implies AR(\infty).$$

Замечание

Почему это важно? Каждый из множителей раскладывается в ряд:

$$(1 - \lambda L)^{-1} = 1 + \lambda L + \lambda^2 L^2 + \dots \quad \text{при } |\lambda| < 1.$$

Этот ряд сходится только при $|\lambda| < 1$ — отсюда и условие обратимости.

4.3. Проблема неидентифицируемости

Важно

Если МА-процесс необратим, то метод максимального правдоподобия (ММП) даёт 2^q локальных максимумов — параметры определяются неоднозначно. Поэтому на практике рассматривают только обратимые МА-процессы.

4.4. Когда необратимость возникает «сама собой»

Иногда необратимость появляется как побочный эффект преобразования. Например, пусть исходный ряд:

$$y_t = \alpha + \beta t + \varepsilon_t \quad (\text{линейный тренд}).$$

Если взять первую разность для устранения тренда:

$$\Delta y_t = y_t - y_{t-1} = \underbrace{\beta + \varepsilon_t - \varepsilon_{t-1}}_{\text{это уже МА(1) с } \beta_1 = -1}.$$

Корень $\lambda_1 = 1$, то есть $|\lambda_1| = 1$ — процесс не обратим. Это и есть тот самый случай «когда необратимость — это плохо»: применили лишнюю разность к тренд-стационарному ряду и получили неприятную МА-структуру.

5. Смешанные модели ARMA(p,q)

Процесс ARMA(p,q)

$$y_t = \underbrace{\alpha_0 + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p}}_{\text{AR-часть}} + \underbrace{\varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}}_{\text{МА-часть (всегда стационарна)}}$$

5.1. Условие стационарности через корни AR-полинома

Напомним: после введения лагового оператора модель ARMA записывается как $\phi(L) x_t = \mu + \theta(L) u_t$, где $\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$.

Условие стационарности ARMA

Модель ARMA задаёт стационарный ряд $\iff$ выполнено условие стационарности:

все корни (в том числе из $\mathbb{C}$) AR-многочлена $\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$
по модулю больше единицы.

То есть все корни должны лежать вне единичного круга на комплексной плоскости.

Замечание

Симметрия с обратимостью. Полная картина:

- Стационарность ARMA $\iff$ корни AR-полинома $\phi(z)$ лежат вне единичного круга ($|z_j| > 1$).
- Обратимость ARMA $\iff$ корни MA-полинома $\theta(z)$ лежат вне единичного круга ($|z_j| > 1$).

(Оба условия — про корни, и оба — «вне единичного круга», когда мы говорим о z . Если же говорить про корни λ в форме $\prod(1 - \lambda_j L)$, то условие наоборот — $|\lambda_j| < 1$, потому что $\lambda_j = 1/z_j$.)

Пример. ARMA(1,q)

Рассмотрим модель

$$x_t = \mu + \phi x_{t-1} + u_t + \sum_{s=1}^q \theta_s u_{t-s}, \quad \phi, \theta_q \neq 0.$$

AR-полином: $\phi(z) = 1 - \phi z$, его единственный корень: $z_0 = 1/\phi$.

Условие стационарности $|z_0| > 1$ эквивалентно $|\phi| < 1$. Получаем известный критерий:

$$\text{Модель ARMA}(1, q) \text{ стационарна} \iff |\phi| < 1.$$

Пример: AR(1) и интуиция. Чтобы понять, почему условие $|\phi| < 1$ так важно, рассмотрим модель $x_t = \phi x_{t-1} + u_t$ и «раскрутим» её назад:

$$\begin{aligned} x_t &= \phi(\phi x_{t-2} + u_{t-1}) + u_t = \phi^2 x_{t-2} + \phi u_{t-1} + u_t \\ &= \phi^3 x_{t-3} + \phi^2 u_{t-2} + \phi u_{t-1} + u_t \\ &\vdots \\ &= \phi^k x_{t-k} + \sum_{j=0}^{k-1} \phi^j u_{t-j}. \end{aligned}$$

Что происходит при $k \rightarrow \infty$?

- Если $|\phi| < 1$: $\phi^k \rightarrow 0$ — вклад далёкого прошлого исчезает, ряд стационарен.
- Если $|\phi| = 1$: ϕ^k не убывает — все прошлые шоки имеют одинаковый вес, ряд нестационарен (это случайное блуждание).
- Если $|\phi| > 1$: $\phi^k \rightarrow \infty$ — вклад прошлого даже усиливается, ряд «взрывается».

5.2. Среднее значение стационарного ARMA

Для стационарного ARMA $\mathbb{E}x_t = \text{const}$ (не зависит от t) и $\mathbb{E}u_s = 0$. Возьмём матожидание от обеих частей уравнения (1):

$$\mathbb{E}x_t = \mu + \sum_{j=1}^p \phi_j \mathbb{E}x_{t-j} + \underbrace{\mathbb{E}u_t}_{=0} + \sum_{s=1}^q \theta_s \underbrace{\mathbb{E}u_{t-s}}_{=0}.$$

Так как $\mathbb{E}x_{t-j} = \mathbb{E}x_t$, получаем:

$$\mathbb{E}x_t = \mu + \left(\sum_{j=1}^p \phi_j \right) \mathbb{E}x_t \implies \left(1 - \sum_{j=1}^p \phi_j \right) \mathbb{E}x_t = \mu.$$

Заметим, что $1 - \sum_j \phi_j = \phi(1)$ — это значение AR-полинома в точке $z = 1$. Итог:

$$\mathbb{E}x_t = \frac{\mu}{1 - \sum_{j=1}^p \phi_j} = \frac{\mu}{\phi(1)}.$$

Что если $\sum \phi_j = 1$?

Если $\sum_j \phi_j = 1$, то $\phi(1) = 0$, и формула $\mathbb{E}x_t = \mu/\phi(1)$ не существует — деление на ноль. Это в точности означает, что $z = 1$ является корнем AR-полинома, и условие стационарности нарушено. Среднего значения у такого ряда просто нет — это случай единичного корня (например, случайное блуждание $x_t = x_{t-1} + u_t$).

Полезное наблюдение про роль μ : если $\sum \phi_j \approx 1$, то $\phi(1)$ маленькое и μ нужно брать большим, чтобы получить разумный средний уровень. И наоборот: если $\sum \phi_j = 0$, то $\mathbb{E}x_t = \mu$ — константа в уравнении сразу даёт средний уровень.

5.3. Представление стационарного ARMA как MA(∞)

Представление через бесконечный MA

Стационарный ARMA(p, q) можно представить как модель скользящего среднего бесконечного порядка MA(∞):

$$x_t = \mu_1 + u_t + \psi_1 u_{t-1} + \psi_2 u_{t-2} + \dots = \mu_1 + u_t + \sum_{j=1}^{\infty} \psi_j u_{t-j},$$

где коэффициенты ψ_j определяются через формальное деление многочленов:

$$\frac{\theta(z)}{\phi(z)} = 1 + \sum_{j=1}^{\infty} \psi_j z^j.$$

Идея вывода. Из $\phi(L)x_t = \mu + \theta(L)u_t$ при условии стационарности (корни $\phi(z)$ вне единичного круга) оператор $\phi(L)$ обратим, и:

$$x_t = \phi(L)^{-1} \mu + \frac{\theta(L)}{\phi(L)} u_t = \mu_1 + \left(1 + \sum_{j=1}^{\infty} \psi_j L^j \right) u_t,$$

где $\mu_1 = \mu/\phi(1)$ — это и есть среднее значение из предыдущего раздела.

Важное следствие

Для стационарной ARMA:

$$\text{Cov}(u_t, x_{t-h}) = 0 \quad \text{при всех } h > 0,$$


то есть внешний шок не коррелирует с прошлыми значениями ряда.

Замечание

Это важно для эконометрики: текущий шок u_t — это «новость», которая ещё не отразилась в прошлом. Прошлые значения x_{t-h} зависят только от прошлых шоков $u_{t-h}, u_{t-h-1}, \dots$, и поэтому ортогональны u_t — что и нужно для состоятельности ОЛС-оценок.

5.4. Иллюстрации: типичные траектории и корреллограммы


Для интуиции полезно посмотреть, как выглядят траектории и корреллограммы (графики ACF/PACF) для разных параметров.



Что видно на рисунке: при $\phi = -0,8$ траектория сильно осциллирует (отрицательная автокорреляция первого порядка — после высоких значений идут низкие). У такой модели на ACF будет ярко выраженная отрицательная корреляция на лаге 1 с последующими затухающими колебаниями.

5.5. Идентификация модели по ACF и PACF


Процесс	ACF	PACF
AR(p)	плавно затухает	обрывается на лаге p
MA(q)	обрывается на лаге q	плавно затухает
ARMA(p, q)	плавно затухает (после лага q)	плавно затухает (после лага p)



Интуиция: Поскольку ARMA содержит и AR-часть, и MA-часть, ни ACF, ни PACF не обрываются полностью — обе функции плавно затухают. Это и осложняет визуальную идентификацию порядка ARMA-моделей.

6. Нестационарные процессы

Все рассмотренные выше модели (AR, MA, ARMA) подходят только для стационарных рядов. Если ряд имеет тренд или единичный корень — нужно сначала привести его к стационарному виду. Существует две принципиально разные стратегии:



6.1. Trend Stationary (TS) процессы

TS-процесс

Процесс является trend stationary, если он становится стационарным после вычитания (детерминированного) тренда:

$$y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \dots + \alpha_k t^k + \varepsilon_t.$$

Стратегия работы с TS:

1. Оцениваем тренд: $\hat{y}_t = \hat{\alpha}_0 + \hat{\alpha}_1 t + \dots + \hat{\alpha}_k t^k$.
2. Вычитаем: $y_t - \hat{y}_t = \hat{\varepsilon}_t$ — этот ряд стационарен.

Важно

Можно «по ошибке» взять разность вместо вычитания тренда — но тогда получится необратимый MA-процесс (см. пример из раздела 3.4). Это типичный случай

переразностной обработки (over-differencing).

6.2. Difference Stationary (DS) процессы

DS-процесс

Процесс является difference stationary, если он становится стационарным после взятия разности (одной или нескольких).

Простейший пример — случайное блуждание (Random Walk):

$$y_t = y_{t-1} + \varepsilon_t.$$

Оператор разности: $\Delta = 1 - L$, где L — лаговый оператор. Тогда:

$$\Delta y_t = (1 - L)y_t = y_t - y_{t-1}.$$

Для случайного блуждания: $\Delta y_t = \varepsilon_t$ — белый шум, стационарен.

6.3. Интегрированные процессы $I(d)$

Процесс $I(d)$

Процесс называется интегрированным порядка d ($y_t \sim I(d)$), если он становится стационарным после d -кратного применения оператора разности:

$$\Delta^d y_t = \varepsilon_t \quad \text{— стационарен.}$$

Высшие степени оператора разности:

$$\Delta^d = (1 - L)^d.$$

Например:

$$\Delta^2 = (1 - L)^2 = 1 - 2L + L^2,$$

то есть

$$\Delta^2 y_t = y_t - 2y_{t-1} + y_{t-2}.$$

Замечание

Стационарный процесс — это $I(0)$. Случайное блуждание — $I(1)$. Если ряд имеет два единичных корня (например, накопленное случайное блуждание) — $I(2)$.

7. ARIMA(p,d,q)

Процесс ARIMA(p,d,q)

Идея: к ряду y_t применяется d -кратная разность для устранения нестационарности, а к полученному стационарному ряду $\Delta^d y_t$ применяется модель ARMA(p, q):

$$\Delta^d y_t = \alpha_1 \Delta^d y_{t-1} + \dots + \alpha_p \Delta^d y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}.$$

Параметры: p — порядок AR, d — порядок интеграции, q — порядок MA.

8. ARIMAX(p,d,q)

Процесс ARIMAX

Расширение ARIMA, в котором добавлены экзогенные регрессоры $x_{1t}, \dots, x_{Kt}$:

$$\Delta^d y_t = \alpha_1 \Delta^d y_{t-1} + \dots + \alpha_p \Delta^d y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q} + \gamma_1 x_{1t} + \dots + \gamma_K x_{Kt}.$$

Буква X в названии — от eXogenous.

Внимание!

Все экзогенные регрессоры x_{kt} должны быть стационарны. Если регрессор x_{kt} имеет ту же интеграцию, что и y_t , то его тоже нужно продифференцировать.

9. ARFIMA(p,d,q)

Процесс ARFIMA

ARFIMA — AutoRegressive Fractionally Integrated Moving Average. Отличие от ARIMA: параметр d может быть дробным (не целым), $d \in \mathbb{R}$.

Используется представление FI(d) (Fractionally Integrated):

$$(1 - L)^d y_t = \varepsilon_t, \quad d \in \mathbb{R}.$$

Зачем нужно дробное d ?

ARFIMA позволяет моделировать ряды с долгой памятью (long memory) — когда автокорреляции затухают медленнее, чем экспоненциально (по степенному закону), но быстрее, чем у нестационарного процесса. Дробная разность $(1 - L)^d$ при $0 < d < 0,5$ как раз даёт стационарный процесс с такой долгой памятью.

Раскладывается через биномиальный ряд:

$$(1 - L)^d = \sum_{k=0}^{\infty} \binom{d}{k} (-L)^k = 1 - dL + \frac{d(d-1)}{2!} L^2 - \frac{d(d-1)(d-2)}{3!} L^3 + \dots$$

10. SARIMA: учёт сезонности

Процесс SARIMA(p,d,q) × (P,D,Q)_s

SARIMA (Seasonal ARIMA) — добавляет к ARIMA сезонную компоненту. Параметры:

- (p, d, q) — несезонные порядки (как в обычной ARIMA),
- (P, D, Q) — сезонные порядки AR, интеграции и MA,
- s — длина сезонного цикла (число наблюдений в одном цикле): для месячных данных $s = 12$, для квартальных $s = 4$, для дневных с недельной сезонностью $s = 7$.

Сезонный оператор разности:

$$\Delta_s^D = (1 - L^s)^D.$$

Например, $\Delta_{12} y_t = y_t - y_{t-12}$ устраняет годовую сезонность для месячных данных.

Полная запись модели:

$$\begin{aligned} \Delta^d \Delta_s^D y_t &= \alpha_1 \Delta^d \Delta_s^D y_{t-1} + \dots + \alpha_p \Delta^d \Delta_s^D y_{t-p} \\ &+ \alpha_1^s \Delta^d \Delta_s^D y_{t-s} + \dots + \alpha_P^s \Delta^d \Delta_s^D y_{t-P \cdot s} \\ &+ \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q} \\ &+ \beta_1^s \varepsilon_{t-s} + \dots + \beta_Q^s \varepsilon_{t-s \cdot Q}. \end{aligned}$$

Замечание

Идея SARIMA в одной фразе: мы берём «обычные» лаги $(1, 2, \dots, p)$ и «сезонные» лаги $(s, 2s, \dots, P \cdot s)$ — и применяем к ним AR, MA и разности независимо. Это позволяет моделировать ряды, где наблюдается и трендовая, и сезонная структура (например, продажи мороженого по месяцам).

11. Итоговая схема классификации моделей

Модель	Назначение / структура
$AR(p)$	Стационарный, зависит от p предыдущих значений ряда
$MA(q)$	Стационарный, зависит от q предыдущих шоков
$ARMA(p, q)$	Стационарный, объединяет AR и MA
$ARIMA(p, d, q)$	ARMA на d -й разности (для DS-процессов)
$ARIMAX(p, d, q)$	ARIMA + экзогенные регрессоры
$ARFIMA(p, d, q)$	ARIMA с дробным d (длинная память)
$SARIMA(p, d, q) \times (P, D, Q)_s$	ARIMA с сезонной компонентой

Алгоритм построения модели для временного ряда (методология Бокса–Дженкинса):

1. Проверить ряд на стационарность (графически и тестами на единичный корень: ADF, KPSS).
2. Если ряд нестационарен — взять разность нужного порядка d (и/или сезонную D).
3. Построить ACF и PACF преобразованного ряда.
4. Идентифицировать p и q по поведению PACF и ACF.
5. Оценить параметры (ОЛС, ММП).
6. Проверить остатки на белый шум (тест Льюнга–Бокса).
7. Сравнить альтернативные модели по AIC/BIC, выбрать лучшую.

