

Эконометрика

Конспект. Лекции 4–5:

Тесты на единичные корни и процедура Бокса–Дженкинса

Содержание

1 Тесты на единичные корни	1
1.1 Тест Дики–Фуллера (Dickey–Fuller)	1
1.2 Спецификации DF-теста	2
1.3 Расширенный тест Дики–Фуллера (ADF)	3
1.4 Другие тесты на стационарность	3
2 Процедура Бокса–Дженкинса (Box–Jenkins)	4
2.1 Шаг 1. Определение порядка интегрирования d	4
2.2 Шаг 2. Определение порядков p и q	4
2.3 Шаг 3. Оценивание модели ARIMA	5
2.4 Информационные критерии	5

1 Тесты на единичные корни

Рассмотрим авторегрессионный процесс первого порядка $AR(1)$:

$$y_t = \alpha y_{t-1} + \varepsilon_t.$$

Проверяемая гипотеза о наличии единичного корня:

$$H_0 : |\alpha| = 1, \quad H_1 : |\alpha| < 1.$$

Общий случай. Тесты на единичные корни в общем случае проводятся для характеристического уравнения. Пусть $\lambda_1, \dots, \lambda_p$ — корни характеристического уравнения процесса $AR(p)$. Тогда

$$H_0 : \exists j : |\lambda_j| = 1, \quad H_1 : \forall j : |\lambda_j| < 1.$$

1.1 Тест Дики–Фуллера (Dickey–Fuller)

Исходное уравнение $AR(1)$:

$$y_t = \alpha y_{t-1} + \varepsilon_t.$$

Вычтем из обеих частей y_{t-1} :

$$\Delta y_t = (\alpha - 1) y_{t-1} + \varepsilon_t.$$

Обозначив $\beta = \alpha - 1$, получаем оцениваемое уравнение:

$$\widehat{\Delta y_t} = \widehat{\beta} y_{t-1} + \varepsilon_t.$$

Гипотезы теста:

$$H_0 : \beta = 0, \quad H_1 : \beta < 0.$$

Статистика теста строится как обычное t -отношение:

$$t = \frac{\widehat{\beta}}{\sqrt{\widehat{D}(\widehat{\beta})}}.$$

Важно. Эта статистика *не* имеет распределения Стьюдента. Она подчиняется специальному *DF-распределению* (*DF test distribution*), для которого используются собственные (нестандартные) критические значения.

1.2 Спецификации DF-теста

DF-тест может проводиться в трёх спецификациях. Их проверяют *итеративно* (в «старомодном» подходе — по очереди: без всего, с константой, с константой и трендом).

1) **Без константы и тренда:**

$$\Delta y_t = \beta y_{t-1} + u_t, \quad H_0 : RW.$$

2) **С константой:**

$$\Delta y_t = \alpha + \beta y_{t-1} + u_t, \quad H_0 : RWD.$$

3) **С константой и трендом:**

$$\Delta y_t = \alpha_0 + \alpha_1 t + \beta y_{t-1} + u_t, \quad H_0 : RWD + T.$$

Нулевые гипотезы в развёрнутом виде:

$$RW : y_t = y_{t-1} + \varepsilon_t,$$

$$RWD : y_t = y_{t-1} + \alpha + u_t,$$

$$RWD + T : y_t = y_{t-1} + \alpha_0 + \alpha_1 t + u_t.$$

Здесь RW — случайное блуждание, RWD — случайное блуждание со сдвигом, $RWD + T$ — случайное блуждание со сдвигом и трендом (стационарный AR за счёт трендовой части).

1.3 Расширенный тест Дики–Фуллера (ADF)

Augmented Dickey–Fuller test позволяет оценивать процессы $AR(p)$. Оцениваемое уравнение:

$$\Delta y_t = \beta y_{t-1} + \alpha_1 \Delta y_{t-1} + \dots + \alpha_k \Delta y_{t-k} + u_t.$$

Вывод для $AR(2)$. Рассмотрим процесс

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + u_t.$$

Вычтем y_{t-1} :

$$\Delta y_t = (\alpha_1 - 1) y_{t-1} + \alpha_2 y_{t-2} + u_t.$$

Прибавим и вычтем $\alpha_2 y_{t-1}$:

$$\Delta y_t = (\alpha_1 - 1) y_{t-1} + \underbrace{\alpha_2 y_{t-1} - \alpha_2 y_{t-1}} + \alpha_2 y_{t-2} + u_t.$$

Сгруппировав слагаемые, получаем:

$$\Delta y_t = (\alpha_2 + \alpha_1 - 1) y_{t-1} - \alpha_2 \Delta y_{t-1} + u_t.$$

Интерпретация. Если сумма коэффициентов $\alpha_1 + \alpha_2 = 1$, то процесс $AR(2)$ имеет единичный корень (это также можно проверить через корни характеристического уравнения).

Гипотезы и статистика теста:

$$H_0 : \beta = 0, \quad H_1 : \beta < 0,$$

$$\frac{\hat{\beta}}{\sqrt{\hat{D}(\hat{\beta})}} \stackrel{H_0}{\approx} ADF_{\text{stat}}.$$

В DF/ADF-тестах альтернатива *всегда односторонняя*. Количество лагов также подбирается (проверяется) в рамках ADF.

1.4 Другие тесты на стационарность

Тест Филлипса–Перрона (PP test)

Аналог ADF, но с другим способом подсчёта статистики. Менее параметрический: не требует нормальности шума.

Тест KPSS

Гипотезы заданы «наоборот» относительно DF/ADF:

$$H_0 : \text{ряд стационарный}, \quad H_1 : \text{ряд нестационарный}.$$

Сравнение тестов. Тесты обладают разными свойствами в плане устойчивости к выбросам, сезонным корректировкам, логарифмированию.

- **KPSS** — самый устойчивый, но менее мощный.

- **ADF** — самый мощный.

На практике лучше проводить все три теста.

2 Процедура Бокса–Дженкинса (Box–Jenkins)

Процедура Бокса–Дженкинса — это подбор оптимальной модели $ARIMA(p, d, q)$ для ряда y_t . Требуется определить три параметра:

$$p-?, \quad d-?, \quad q-?$$

Шаги 1 и 2 — идентификация модели $ARIMA$, шаг 3 — её оценивание.

2.1 Шаг 1. Определение порядка интегрирования d

Параметр d — количество разностей, которое нужно взять, чтобы ряд стал стационарным (то есть чтобы исчезли единичные корни). Алгоритм итеративный:

$$y_t \xrightarrow{ADF} \begin{cases} \text{стационарен} \Rightarrow d = 0, \\ \text{нестационарен} \Rightarrow \Delta y_t \xrightarrow{ADF} \begin{cases} \text{стац.} \Rightarrow d = 1, \\ \text{нестаци.} \Rightarrow \Delta^2 y_t \xrightarrow{ADF} \dots \end{cases} \end{cases}$$

2.2 Шаг 2. Определение порядков p и q

Для уже продифференцированного ряда $\Delta^d y_t$ строят автокорреляционную функцию (ACF) и частную автокорреляционную функцию (PACF).

- Порядок q определяют по графику **ACF**: ищут лаг, после которого значения «обрываются» (становятся незначимыми). На графике ACF из конспекта обрыв происходит после третьего лага $\Rightarrow q = 3$.
- Порядок p определяют по графику **PACF** аналогично: ищут наибольший «скачок» между значимыми и незначимыми столбиками. В конспекте $\Rightarrow p = 2$.

Замечание 1. p и q подбираются «методом пристального взгляда»: смотрят, где наибольший скачок между столбиками (между значимым и незначимым значением). Тесты ниже нужны для проверки значимости.

Тесты на значимость автокорреляций. Проверяемая гипотеза:

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_n = 0.$$

- **Box–Pierce test** — статистика

$$T \sum_{k=1}^n \hat{\rho}_k^2.$$

- **Ljung–Box test** — уточнённая статистика

$$T(T+2) \sum_{k=1}^n \frac{\hat{\rho}_k^2}{T-k}.$$

2.3 Шаг 3. Оценивание модели ARIMA

Модель связывает $\Delta^d y_t$ с её собственными лагами и лагами ошибок:

$$\Delta^d y_t \sim \underbrace{\Delta^d y_{t-1}, \dots, \Delta^d y_{t-p}}_{\text{есть «цифры» (наблюдаемые)}}, \underbrace{\varepsilon_{t-1}, \dots, \varepsilon_{t-q}}_{\text{нет «цифр» (ненаблюдаемые)}}.$$

Проблема ненаблюдаемых ошибок. Поскольку прошлые ошибки ненаблюдаемы, делается предположение о нулевых «старых» ошибках:

$$\begin{aligned}\varepsilon_1 &= \Delta^d y_t - \alpha_1 \Delta^d y_{t-1} - \dots - \alpha_p \Delta^d y_{t-p} - 0 - \dots - 0, \\ \varepsilon_2 &= \dots - \beta_1 \varepsilon_1 - 0 - \dots - 0.\end{aligned}$$

Способы оценивания.

- 1) Оценка модифицированным МНК (заменяя ε_{t-1} на $\widehat{\varepsilon}_{t-1}$).
- 2) Фильтр Калмана.
- 3) GMM (обобщённый метод моментов).
- 4) Байесовский подход.

Метод максимального правдоподобия (ML). Самый «правильный» подход. Ошибки выражаются через наблюдаемые величины:

$$\varepsilon_t = \Delta^d y_t - \alpha_1 \Delta^d y_{t-1} - \dots - \alpha_p \Delta^d y_{t-p} - \beta_1 \varepsilon_{t-1} - \dots - \beta_q \varepsilon_{t-q}.$$

Предполагается совместная нормальность вектора ошибок:

$$\begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_t \end{pmatrix} \sim N(0, V),$$

где V — ковариационная матрица (формируется по МА-части модели).

2.4 Информационные критерии

Более современный подход к отбору модели — использование информационных критериев.

Критерий Акаике (Akaike Info Criterion, AIC):

$$AIC = 2k - 2 \ln \widehat{L}.$$

Критерий Шварца (Schwartz IC, он же Bayesian IC, BIC):

$$SIC/BIC = k \ln T - 2 \ln \widehat{L}.$$

Обозначения:

- k — число всех оцениваемых коэффициентов модели, $k = p + q$;
- T — количество наблюдений;
- $\hat{L}$ — функция правдоподобия.

По природе оба критерия — *штрафы*: чем меньше значение, тем лучше модель. Значения лежат в $(-\infty, +\infty)$ и растут с увеличением числа коэффициентов.

Свойства при отборе моделей.**AIC — эффективность.**

Если истинной модели нет в множестве рассматриваемых, AIC отбирает наиболее близкую к истинной.

BIC — состоятельность.

Сильнее штрафует за лишние коэффициенты $\Rightarrow$ меньше риск переобучения (overfit).

Если истинная модель есть в множестве рассматриваемых, BIC её отбирает.

