

Эконометрика

Лекция 5:

Прогнозирование по ARIMA и многомерные модели

Содержание

1	Прогнозирование по ARIMA	1
1.1	Переход к уровням	1
1.2	Прогноз на один шаг вперёд	2
1.3	Прогноз на несколько шагов вперёд	2
2	Доверительные интервалы для прогноза	3
2.1	Общая формула дисперсии прогноза	3
2.2	Пример: AR(1)	3
2.3	Fan chart	4
3	Многомерные модели	4
3.1	Модель ARIMAX	4
3.2	Пример: AR(1) с внешним регрессором	4
4	Модель ARDL	6
4.1	Импульсный отклик для ARDL	6
4.2	IRF и доверительные интервалы	6

1 Прогнозирование по ARIMA

Рассмотрим модель $ARIMA(p, 1, q)$ — с интегрированием первого порядка:

$$\Delta y_t = \alpha_0 + \alpha_1 \Delta y_{t-1} + \dots + \alpha_p \Delta y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}.$$

Это $ARMA(p, q)$, применённый не к самому ряду y_t , а к его разностям $\Delta y_t = y_t - y_{t-1}$. Параметр $d = 1$ означает «однократно проинтегрированный» процесс. Для прогноза удобнее перейти от разностей обратно к уровням y_t .

1.1 Переход к уровням

Подставляем $\Delta y_t = y_t - y_{t-1}$:

$$y_t - y_{t-1} = \alpha_0 + \alpha_1 (y_{t-1} - y_{t-2}) + \dots + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots$$

После перегруппировки:

$$y_t = \alpha_0 + (1 + \alpha_1) y_{t-1} + (\alpha_2 - \alpha_1) y_{t-2} + \dots + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}.$$

Получилось обычное уравнение для уровней с пересчитанными коэффициентами. Теперь можно строить прогноз $\hat{y}_{t+h|t}$ — прогноз y_{t+h} , сделанный в момент t .

1.2 Прогноз на один шаг вперёд

Для момента $t + 1$:

$$y_{t+1|t} = \alpha_0 + (1 + \alpha_1) y_t + \dots + \underbrace{\varepsilon_{t+1}}_{\mathbb{E}(\varepsilon_{t+1})=0} + \beta_1 \varepsilon_t + \dots$$

Будущая ошибка ε_{t+1} нам неизвестна — в прогноз подставляется её ожидание, 0. Используя оценки коэффициентов:

$$\hat{y}_{t+1|t} = \hat{\alpha}_0 + (1 + \hat{\alpha}_1) y_t + \dots + \hat{\beta}_1 \varepsilon_t + \dots$$

1.3 Прогноз на несколько шагов вперёд

При прогнозе на $h = 2$:

$$\hat{y}_{t+2|t} = \hat{\alpha}_0 + (1 + \hat{\alpha}_1) \hat{y}_{t+1|t} + \dots + \underbrace{\hat{\beta}_1 \cdot 0}_{\mathbb{E}(\varepsilon_{t+1})=0} + \hat{\beta}_2 \varepsilon_t + \dots$$

Прогноз строится итеративно: y_{t+1} прогнозируется по y_t , y_{t+2} — по уже спрогнозированному $\hat{y}_{t+1|t}$ и так далее. Будущие ошибки везде заменяются нулями, прошлые ошибки берутся из остатков модели.

При $h > q$ МА-часть «выдыхается». Все прошлые ошибки уже использованы — остаются только AR-члены:


$$\hat{y}_{t+h|t} = \hat{\alpha}_0 + (1 + \hat{\alpha}_1) \hat{y}_{t+h-1|t} + \dots \quad (\beta \text{ не будет}).$$

Качественное поведение прогноза.

- Для **стационарного** ряда прогноз быстро возвращается к константе (среднему уровню ряда).
- Для **нестационарного** ряда прогноз продолжает двигаться вместе с трендом.

Если горизонт прогноза $h > \max(p, q)$, то обычно прогноз — это либо константа, либо тренд.

Практическое правило. ARIMA хорошо строит прогнозы на 2–3 шага вперёд. На большем горизонте можно, но не особо полезно — модель теряет информативность.



2 Доверительные интервалы для прогноза

Прогноз — это случайная величина. Его дисперсия складывается из *двух источников*:

1. неопределённость оценок коэффициентов $\hat{\alpha}, \hat{\beta}$;
2. неопределённость будущих ошибок ε .

2.1 Общая формула дисперсии прогноза

$$D(\hat{y}_{t+1|t}) = D(\hat{\alpha}_0 + (1 + \hat{\alpha}_1) y_t + \dots + \hat{\beta}_1 \varepsilon_t + \dots).$$

Раскрывая (с учётом ковариаций между оценками):

$$D(\hat{y}_{t+1|t}) = D(\hat{\alpha}_0) + y_t^2 D(\hat{\alpha}_1) + \dots + y_t \text{cov}(\hat{\alpha}_0, \hat{\alpha}_1) + \dots + \sigma_\varepsilon^2.$$

Первая часть — дисперсия линейной комбинации оценок коэффициентов (зависит от значений y, ε и ковариационной матрицы оценок). Вторая — собственная дисперсия будущего шока ε_{t+1} , она равна σ_ε^2 .

$$D(\hat{y}_{t+1|t}) = \hat{D}(\dots) + \sigma_\varepsilon^2$$

2.2 Пример: AR(1)

Рассмотрим простую модель $\hat{y}_t = \hat{\alpha} y_{t-1}$. Прогнозы на разные горизонты:

$$\begin{aligned} \hat{y}_{t+1|t} &= \alpha y_t + \varepsilon_{t+1}, \\ \hat{y}_{t+2|t} &= \alpha^2 y_t + \alpha \varepsilon_{t+1} + \varepsilon_{t+2}, \\ \hat{y}_{t+3|t} &= \alpha^3 y_t + \alpha^2 \varepsilon_{t+1} + \alpha \varepsilon_{t+2} + \varepsilon_{t+3}. \end{aligned}$$

На каждом шаге появляется новый шок плюс «отголоски» предыдущих шоков, умноженные на степени α . Чем дальше горизонт, тем больше слагаемых, и каждое из них ещё умножается на квадрат степени α в дисперсии.

Дисперсии прогнозов:


$$\begin{aligned} D(\hat{y}_{t+1|t}) &= \hat{D}(\hat{\alpha}) y_t^2 + \sigma^2, \\ D(\hat{y}_{t+2|t}) &= \hat{D}(\hat{\alpha}^2) y_t^2 + \hat{D}(\hat{\alpha}) \sigma^2 + \sigma^2, \\ D(\hat{y}_{t+3|t}) &= \hat{D}(\hat{\alpha}^3) y_t^2 + \hat{D}(\hat{\alpha}^2) \sigma^2 + \hat{D}(\hat{\alpha}) \sigma^2 + \sigma^2. \end{aligned}$$

Главный вывод. Дисперсия прогноза *растёт с горизонтом прогнозирования*. Это и есть формальное обоснование того, почему дальние прогнозы менее надёжны.

2.3 Fan chart

Графически результат выглядит как **веер** (fan chart): доверительный интервал расширяется по мере удаления от настоящего момента.

Внутри «веера» закрашивают зоны разных доверительных уровней (50 %, 80 %, 95 %) — отсюда и название. Используется в отчётах центробанков (Банк Англии популяризировал такой способ изображения прогнозов инфляции).



Fan chart: доверительный интервал расширяется с ростом горизонта прогноза.

3 Многомерные модели

В реальности на y_t могут влиять и *другие* ряды x_t . Чтобы это учесть, в модель добавляют экзогенные переменные.

3.1 Модель ARIMAX

ARIMAX = ARIMA + eXogenous variables: расширение ARIMA, в котором правую часть дополняют внешние регрессоры:

$$\Delta^d y_t = \alpha_0 + \alpha_1 \Delta^d y_{t-1} + \dots + \gamma_1 x_{1t} + \dots + \gamma_k x_{kt}.$$

Проверка значимости экзогенной переменной.

$$H_0 : \gamma_1 = 0, \quad H_1 : \gamma_1 \neq 0.$$

Если гипотеза H_0 отвергается, переменная x_1 значимо влияет на y .

3.2 Пример: AR(1) с внешним регрессором

Предположим $|\alpha_1| < 1$ (ряд стационарен). Модель:

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \gamma x_t + \varepsilon_t.$$

Допустим, оценили $\gamma = 5$. Как реакция y распространяется во времени?

Мгновенный эффект.

$$\frac{\partial y_t}{\partial x_t} = \gamma = 5.$$

Эффект через один период. В уравнении для $y_{t+1} = \alpha_0 + \alpha_1 y_t + \gamma x_{t+1} + \varepsilon_{t+1}$ переменная x_t входит только через y_t :

$$\frac{\partial y_{t+1}}{\partial x_t} = \alpha_1 \cdot \frac{\partial y_t}{\partial x_t} = \alpha_1 \cdot 5.$$

Эффект через два периода.

$$\frac{\partial y_{t+2}}{\partial x_t} = \alpha_1 \cdot \frac{\partial y_{t+1}}{\partial x_t} = \alpha_1^2 \cdot 5.$$

В общем виде:



$$\frac{\partial y_{t+h}}{\partial x_t} = \alpha_1^h \cdot \gamma.$$

Шок в x_t распространяется по цепочке: сначала меняет y_t , потом y_{t+1} через AR-член $\alpha_1 y_t$, потом y_{t+2} через $\alpha_1 y_{t+1}$ и т.д. Каждый шаг даёт дополнительный множитель α_1 .

Импульсный отклик (Impulse Response Function, IRF) — зависимость $\partial y_{t+h}/\partial x_t$ от горизонта h .

Поведение зависит от знака α_1 :

- $\alpha_1 > 0$ — IRF монотонно затухает (экспоненциальное убывание);
- $\alpha_1 < 0$ — IRF колеблется (знак чередуется) и затухает.



Импульсный отклик (IRF) для AR(1) с экзогенным регрессором: $\partial y_{t+h}/\partial x_t = \alpha_1^h \cdot \gamma$.

4 Модель ARDL

ARDL (*AutoRegressive Distributed Lags*) — общий вид многомерной модели с лагами как y , так и x . Предполагаем стационарность обоих рядов:

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \gamma_0 x_t + \gamma_1 x_{t-1} + \dots + \gamma_\ell x_{t-\ell} + \varepsilon_t.$$

«Distributed lags» — «распределённые лаги»: эффект x распределён по нескольким периодам через коэффициенты $\gamma_0, \gamma_1, \dots, \gamma_\ell$. ARDL — обобщение и ARIMAX, и обычной авторегрессии.

4.1 Импульсный отклик для ARDL

Считаем влияние x_t на будущие значения y :

$$\frac{\partial y_t}{\partial x_t} = \gamma_0.$$

$$\frac{\partial y_{t+1}}{\partial x_t} = \alpha_1 \cdot \frac{\partial y_t}{\partial x_t} + \gamma_0 \cdot \underbrace{\frac{\partial x_{t+1}}{\partial x_t}}_{=?} + \gamma_1.$$

Вопрос: чему равно $\partial x_{t+1} / \partial x_t$? Если считать x_t независимыми, то нullo. Если же есть динамическая модель для x — нужно учитывать её. Поэтому на практике используют **Bootstrap** (имитационный метод): руками такое не считают.


$$\frac{\partial y_{t+2}}{\partial x_t} = \alpha_1 \cdot \frac{\partial y_{t+1}}{\partial x_t} + \alpha_2 \cdot \frac{\partial y_t}{\partial x_t} + \gamma_0 \frac{\partial x_{t+2}}{\partial x_t} + \gamma_1 \frac{\partial x_{t+1}}{\partial x_t} + \gamma_2.$$

И так далее. В общем виде получается рекуррентная формула, в которой вклад на каждом горизонте складывается из «отголосков» через y и через лаги x .

4.2 IRF и доверительные интервалы

Типичный график IRF для ARDL:

- кривая может иметь немонотонный вид (с горбом и впадиной);
- вокруг неё строят доверительный интервал — он расширяется с ростом h .



Типичный вид IRF для ARDL: немонотонная кривая с расширяющимся с ростом h доверительным интервалом.

Расчёт доверительного интервала: Bootstrap. Аналитически считать дисперсию IRF в ARDL очень сложно, поэтому на практике используют имитационный метод:

1. многократно (~ 100 раз) генерируют псевдо-выборки;
2. на каждой переоценивают модель и считают IRF;
3. по совокупности IRF получают эмпирический доверительный интервал.

Руками такое не считают