

Эконометрика

Сборник лекций.

Временные ряды

Содержание

Лекция I. Введение, ETS-модели, белый шум и случайное блуждание	5
I.1 Введение в анализ временных рядов	5
I.2 ETS-модели: Error, Trend, Seasonality	5
I.3 Временные ряды в эконометрике	6
I.4 Случайное блуждание (Random Walk)	7
Лекция II. Стационарность. AR(1), MA(q) и теорема Вольда	9
II.1 Понятие стационарности	9
II.1.1 Строгая стационарность (сильная, в узком смысле)	9
II.1.2 Слабая стационарность (нестрогая, в широком смысле)	10
II.2 Авторегрессионный процесс AR(p)	10
II.2.1 AR(1) — авторегрессионный процесс первого порядка	10
II.2.2 Авторегрессионный процесс порядка p — AR(p)	11
II.3 Лаговый оператор	12
II.4 Процесс скользящего среднего — MA(q)	12
II.5 Теорема Вольда (декомпозиция Вольда)	13
Лекция III. AR-процессы: стационарность, ACF и PACF	15
III.1 Стационарность AR(p)-процесса	15
III.1.1 Критерий стационарности	15
III.2 Автокорреляционная функция (ACF)	16
III.3 Уравнения Юла–Уокера	17
III.4 Частная автокорреляционная функция (PACF)	19
Лекция IV. Модели ARMA, ARIMA, SARIMA	21
IV.1 Лаговый оператор и формальная запись моделей	21
IV.2 ACF и PACF: различение AR и MA процессов	22
IV.3 Авторегрессионные процессы AR(p)	22

IV.4 Процессы скользящего среднего $MA(q)$	23
IV.5 Смешанные модели $ARMA(p, q)$	24
IV.6 Нестационарные процессы	26
IV.6.1 Trend Stationary (TS) процессы	26
IV.6.2 Difference Stationary (DS) процессы	27
IV.6.3 Интегрированные процессы $I(d)$	27
IV.7 $ARIMA(p, d, q)$	27
IV.8 $ARIMAX(p, d, q)$	27
IV.9 $ARFIMA(p, d, q)$	28
IV.10 $SARIMA$: учёт сезонности	28
IV.11 Итоговая схема классификации моделей	29
 Лекция V. Тесты на единичные корни и процедура Бокса–Дженкинса	 30
V.1 Тесты на единичные корни	30
V.1.1 Тест Дики–Фуллера (Dickey–Fuller)	30
V.1.2 Спецификации DF-теста	31
V.1.3 Расширенный тест Дики–Фуллера (ADF)	31
V.1.4 Другие тесты на стационарность	32
V.2 Процедура Бокса–Дженкинса (Box–Jenkins)	32
V.2.1 Шаг 1. Определение порядка интегрирования d	32
V.2.2 Шаг 2. Определение порядков p и q	33
V.2.3 Шаг 3. Оценивание модели $ARIMA$	33
V.2.4 Информационные критерии	34
 Лекция VI. Прогнозирование по $ARIMA$ и многомерные модели	 36
VI.1 Прогнозирование по $ARIMA$	36
VI.2 Доверительные интервалы для прогноза	37
VI.3 Многомерные модели	38
VI.3.1 Модель $ARIMAX$	39
VI.3.2 Пример: $AR(1)$ с внешним регрессором	39
VI.4 Модель $ARDL$	40
VI.4.1 Импульсный отклик для $ARDL$	40
VI.4.2 IRF и доверительные интервалы	41

Лекция VII. Векторная авторегрессия (VAR): структурная форма, импульсный отклик, FEVD **42**

VII.1 Векторная авторегрессия **42**

VII.1.1 Приведенная форма	42
VII.1.2 Структурная форма и проблема одновременности	42
VII.1.3 Интерпретация: функции импульсного отклика	43
VII.1.4 Декомпозиция дисперсии ошибки прогноза (FEVD)	43
VII.1.5 Итоги лекции 7	44

Лекция VIII. Коинтеграция: тесты Энгла-Грейнджера и Йохансена, модели ЕСМ и VECM **45**

VIII.1 Коинтеграция **45**

VIII.1.1 Ложные корреляции и идея коинтеграции	45
VIII.1.2 Тесты на коинтеграцию	46
VIII.1.3 Модель коррекции ошибок (ЕСМ)	46
VIII.1.4 Векторная модель коррекции ошибок (VECM)	47
VIII.1.5 Итоги лекции 8	47

Лекция I

Введение, ETS-модели, белый шум и случайное блуждание

I.1 Введение в анализ временных рядов

Временные ряды в рамках базовой эконометрики

При работе с временными рядами практически всегда возникает проблема *автокорреляции*:

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t, \quad \text{corr}(\varepsilon_t, \varepsilon_{t-1}) \neq 0.$$

Также возникает проблема *эндогенности*, когда необходимо учитывать инерцию внутри модели:

$$Y_t = \beta_0 + \beta_1 X_t + \underbrace{\beta_2 Y_{t-1}}_{\text{инерция}} + \varepsilon_t, \quad \text{corr}(Y_{t-1}, \varepsilon_t) \rightarrow \text{эндогенность}.$$

Начало развития метрики

Историческая шкала развития моделей временных рядов:

Модель	Год	Класс
ETS (Exponential Smoothing)	1830	сглаживание
SSM (State Space Models)	1940	пространство состояний
ARIMA	1960	линейные стохастические модели
ML (Maximum Likelihood)	1970	метод оценивания
VAR (Vector AutoRegression)	1980	многомерные модели
Prophet (модель Facebook)	1990	декомпозиция тренда/сезона
Глубокие нейросети для рядов	2017	машинное обучение

Особенности TS-моделей:

- как правило, очень мало данных (и их количество очень сложно увеличить);
- как правило, хорошо получается справляться с задачей прогнозирования;
- в продвинутых моделях учитывается структура.

I.2 ETS-модели: Error, Trend, Seasonality

В рамках модели ETS предполагается, что временной ряд представляет из себя смесь тренда, сезонности и ошибок.

ETS(A,N,N) — без тренда и сезонности

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha) Y_{t-1}.$$

Разворачивая рекуррентно:

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha) \underbrace{(\alpha Y_{t-1} + \alpha(1 - \alpha) Y_{t-2} + \alpha(1 - \alpha)^2 Y_{t-3} + \dots)}_{\text{бесконечно убывающая геометрическая прогрессия}}.$$

Сумма весов: $\alpha(1 + (1 - \alpha) + (1 - \alpha)^2 + \dots) = 1$.

Компонентная форма:

$$\begin{cases} \hat{Y}_{t+1} = \ell_t & \text{— уравнение прогноза} \\ \ell_t = \alpha Y_t + (1 - \alpha) \ell_{t-1} & \text{— уравнение уровня} \end{cases}$$

ETS(A,A,N) — с трендом, без сезонности

$$\begin{cases} \hat{Y}_{t+1} = \ell_t + h b_t & \text{Forecast equation} \\ \ell_t = \alpha Y_t + (1 - \alpha)(\ell_{t-1} - b_{t-1}) & \text{Level equation} \\ b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1} & \text{Trend equation} \end{cases}$$

Здесь h — лаг (сдвиг).

ETS(A,A,A) — с трендом и сезонностью

$$\begin{cases} \hat{Y}_{t+1} = \ell_t + h b_t + S_{t+h-m(k+1)} & \text{Forecast equation} \\ \ell_t = \alpha(Y_t - S_{t-m}) + (1 - \alpha)(\ell_{t-1} - b_{t-1}) & \text{Level equation} \\ b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1} & \text{Trend equation} \\ S_t = \gamma(Y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)S_{t-m} & \text{Season equation} \end{cases}$$


Здесь m — число наблюдений в одном году, $k = \lfloor n/m \rfloor$ — число помноженных лет между t и $t + h$.

I.3 Временные ряды в эконометрике

Пусть Y_t — временной ряд, $t = 1, \dots, T$ — время (без пропусков и *equally spaced*).

Ошибку представляем в виде *белого шума*:

$$\varepsilon_t \sim WN, \quad \mathbb{E}(\varepsilon_t) = 0, \quad D(\varepsilon_t) = \sigma^2, \quad \text{cov}(\varepsilon_t, \varepsilon_{t-j}) = 0 \quad \forall j \neq 0.$$



Замечание I.3.1. Equally spaced — то есть между измерениями одинаковые интервалы (используем наблюдения, измеренные с одинаковой частотой: от квартала к кварталу, от года к году...). Мы предполагаем (сейчас), что високосный год игнорируется, хотя статистически это не всегда будет корректно. Это допущение о времени важно для классических методов, так как они работают с лаговыми структурами. Если шаги неравномерные, лаг = 3 означает разное физическое время в разных местах ряда, и модель ошибается.

Замечание I.3.2. Любой временной ряд можно представить как сумму синусоид разных частот — разложение Фурье.

Спектр ряда — проекция ряда на пространство разной частоты.

Белый шум — плоский спектр, все частоты одинаковые. Полностью случайный, без памяти, каждое наблюдение независимо от предыдущего. Существуют также и цветные шумы, которые имеют изменяющуюся спектральную плотность.

Разные варианты рядов

Ряд белого шума: $Y_t = \varepsilon_t$.

$$\mathbb{E}(Y_t) = \mathbb{E}(\varepsilon_t) = 0, \quad D(Y_t) = D(\varepsilon_t) = \sigma^2.$$

Ряд с линейным трендом: $Y_t = a + bt + \varepsilon_t$.

$$\mathbb{E}(Y_t) = a + bt + \mathbb{E}(\varepsilon_t) = a + bt,$$

$$D(Y_t) = D(a + bt + \varepsilon_t) = \sigma^2,$$

так как $a + bt$ — константы (детерминированная часть). При этом $\text{cov}(Y_t, Y_{t-1}) = 0$.

I.4 Случайное блуждание (Random Walk)

$$Y_t = Y_{t-1} + \varepsilon_t.$$

Математическое ожидание. Раскручивая рекуррентно:

$$\mathbb{E}(Y_t) = \mathbb{E}(Y_{t-1}) + \mathbb{E}(\varepsilon_t) = \dots = \mathbb{E}(Y_0) + \sum_{j=0}^t \mathbb{E}(\varepsilon_{t-j}).$$

Дисперсия.

$$D(Y_t) = D\left(Y_0 + \sum_{j=1}^t \varepsilon_j\right) = \sum_{j=1}^t D(\varepsilon_j) = t\sigma^2.$$

Автоковариация.

$$\text{cov}(Y_t, Y_{t-1}) = \text{cov}(Y_{t-1} + \varepsilon_t, Y_{t-1}) = \text{cov}(Y_{t-1}, Y_{t-1}) + \text{cov}(\varepsilon_t, Y_{t-1}) = D(Y_{t-1}) = (t-1)\sigma^2.$$



В общем виде автоковариационная функция:

$$\gamma_j = \text{cov}(Y_t, Y_{t-j}) = (t-j)\sigma^2.$$

Автокорреляция.

$$\rho_j = \text{corr}(Y_t, Y_{t-j}) = \frac{\gamma_j}{\sqrt{D(Y_t) D(Y_{t-j})}} = \frac{(t-j)\sigma^2}{\sqrt{t\sigma^2}\sqrt{(t-j)\sigma^2}} = \sqrt{\frac{t-j}{t}}.$$

Как будет выглядеть случайное блуждание на графике? Поскольку между Y_t и Y_{t-1} достаточно сильная корреляция, наблюдения не будут хаотично «разлетаться»:




Лекция II

Стационарность. AR(1), MA(q) и теорема Вольда

II.1 Понятие стационарности

Рассмотрим процесс вида $y_t = \alpha y_{t-1} + \varepsilon_t$. При $\alpha = 1$ получаем случайное блуждание. При $\alpha = 0,99$ (или любом $|\alpha| < 1$) картина ряда кардинально меняется: вместо «уплывающего» ряда со случайным блужданием получаем процесс, который ведёт себя схоже с белым шумом — нет ни явного тренда, ни нарастающих колебаний.

Этот эффект маленького перехода через единицу связан со свойством *стационарности* рядов.



Сравнение процессов вида $y_t = \alpha y_{t-1} + \varepsilon_t$ при $\alpha = 1$ (слева) и $\alpha = 0,9$ (справа) на одних и тех же реализациях белого шума $\varepsilon_t \sim N(0; 0,16)$. При $\alpha = 1$ дисперсия растёт линейно со временем; при $|\alpha| < 1$ процесс возвращается к нулю.

II.1.1 Строгая стационарность (сильная, в узком смысле)

Временной ряд $\{y_t\}$ называется *строго (сильно) стационарным*, если любая конечномерная совместная функция распределения (или плотности) инвариантна относительно сдвига по времени:

$$f(y_{t_1}, \dots, y_{t_n}) = f(y_{t_1+\Delta}, \dots, y_{t_n+\Delta})$$

для любых $n, t_1, \dots, t_n$ и любого целого Δ .

Следствия строгой стационарности:

- $\mathbb{E}[y_t] = \text{const}$,
- $D(y_t) = \text{const}$,
- $\text{cov}(y_t, y_{t-k}) = \gamma(k)$ — функция только лага k , не зависит от времени t .

Проблема: строгую стационарность практически невозможно проверить, но это хорошая теоретическая концепция, на основе которой можно говорить о *слабой* стационарности (используемой по умолчанию).

II.1.2 Слабая стационарность (нестрогая, в широком смысле)

Временной ряд $\{y_t\}$ называется *слабо стационарным*, если выполнены все три условия:

- $\mathbb{E}[y_t] = \mu = \text{const}$ (не зависит от t);
- $D(y_t) = \sigma_y^2 < \infty$ (конечна и не зависит от t);
- $\text{cov}(y_t, y_{t-k}) = \gamma(k)$ (зависит только от лага k , не зависит от t).

Замечание II.1.1. Строгая стационарность влечёт слабую. Обратное неверно. Когда говорят просто «ряд стационарный», по умолчанию имеется в виду слабая стационарность.

Важный нюанс: безусловные vs. условные моменты. Слабая стационарность — это условие на *безусловные* моменты.

Из того, что $\mathbb{E}[y_t] = \text{const}$, *не следует*, что $\mathbb{E}[y_t \mid y_{t-1}]$ тоже константа. Условные моменты вполне могут зависеть от времени — и в большинстве реальных процессов именно так и есть. Именно поэтому эконометрика временных рядов и имеет смысл: она изучает, как прошлое влияет на текущее значение.

Случайное блуждание ($y_t = y_{t-1} + \varepsilon_t$) — пример нестационарного процесса. Свойства (при $y_0 = 0$):

$$\mathbb{E}[y_t] = 0, \quad D(y_t) = t\sigma^2 \text{ — растёт со временем,} \quad \text{cov}(y_t, y_{t-k}) = (t-k)\sigma^2 \text{ — зависит от } t.$$

Дисперсия и ковариация не постоянны во времени $\Rightarrow$ процесс не является слабо стационарным.

II.2 Авторегрессионный процесс AR(p)

II.2.1 AR(1) — авторегрессионный процесс первого порядка

Определение.

$$y_t = \alpha y_{t-1} + \varepsilon_t, \quad |\alpha| < 1,$$

где $\varepsilon_t \sim WN(0, \sigma^2)$, $\text{cov}(\varepsilon_t, \varepsilon_s) = 0$ при $t \neq s$.

Представление через прошлые шоки. Подставляя рекуррентно:

$$y_t = \alpha^t y_0 + \alpha^{t-1} \varepsilon_1 + \alpha^{t-2} \varepsilon_2 + \dots + \alpha \varepsilon_{t-1} + \varepsilon_t.$$

При $|\alpha| < 1$ коэффициент $\alpha^t \rightarrow 0$ при $t \rightarrow \infty$, то есть влияние начального условия y_0 затухает.

Техническое допущение. Считаем, что процесс стартовал в $t = -\infty$. Тогда начальный член исчезает, и:

$$y_t = \underbrace{\alpha^\infty y_\infty}_0 + \sum_{j=-\infty}^t \alpha^{t-j} \varepsilon_j = \sum_{j=-\infty}^t \alpha^{t-j} \varepsilon_j = MA(\infty).$$

Если считать от $t = 0$, то $\mathbb{E}[y_t] = \alpha^t y_0$, что зависит от t и нарушает стационарность. Допущение $t \rightarrow -\infty$ позволяет этого избежать. На практике это оправданно: 30–40 лет наблюдений для большинства задач практически эквивалентны «бесконечному» прошлому.

Свойства AR(1) при $|\alpha| < 1$.

$$\begin{aligned} \mathbb{E}[y_t] &= \sum_{j=-\infty}^t \alpha^j \mathbb{E}[\varepsilon_{t-j}] = 0, \\ D(y_t) &= \sum_{j=-\infty}^t (\alpha^2)^{t-j} \sigma^2 = \frac{\sigma^2}{1 - \alpha^2}, \\ \gamma(k) &= \text{cov}(y_t, y_{t-k}) = \frac{\alpha^k \sigma^2}{1 - \alpha^2}. \end{aligned}$$

Дисперсия — сумма бесконечно убывающей геометрической прогрессии, конечна и не зависит от t . Автоковариация зависит только от лага k , не от t .

Вывод. AR(1) при $|\alpha| < 1$ является *слабо стационарным*. При $|\alpha| \geq 1$ — нестационарен.

II.2.2 Авторегрессионный процесс порядка p — AR(p)

Определение.

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \varepsilon_t.$$

AR(p) — одна из двух базовых моделей временных рядов в эконометрике.

Содержательная интерпретация. AR(p) хорошо отражает реальные экономические процессы. Например, ВВП страны в текущем периоде, скорее всего, связан с ВВП предыдущих периодов: производственные мощности не меняются мгновенно.

В финансах AR(1)-структура для цен активов возникает из гипотезы эффективного рынка: если вся доступная информация уже учтена в цене, то изменение цены описывается шумом, а сама цена — AR(1)-подобным процессом.

Стационарность AR(p). Для AR(1) условие стационарности: $|\alpha| < 1$. Для AR(p) условие стационарности формулируется через корни характеристического полинома (будет рассмотрено в следующей лекции). Для последующего вывода необходимо ввести *лаговый оператор* L .

II.3 Лаговый оператор

Определение. Лаговый оператор L (также обозначается B — backshift operator) действует на временной ряд по правилу:

$$Ly_t = y_{t-1}, \quad L^k y_t = y_{t-k}.$$

Это *оператор*, а не число — он задаёт действие (сдвиг ряда).

Примеры.

$$L^k y_t = y_{t-k}, \quad (L + \alpha L^2)y_t = y_{t-1} + \alpha y_{t-2}.$$

С лаговым оператором можно работать алгебраически, почти как с числом — складывать в суммы, возводить в степени.

AR(p) в операторной записи. AR(p) можно записать компактно:

$$(1 - \alpha_1 L - \alpha_2 L^2 - \dots - \alpha_p L^p)y_t = \alpha_0 + \varepsilon_t,$$

или $\Phi(L)y_t = \varepsilon_t$, где $\Phi(L)$ — лаговый полином порядка p .

По основной теореме алгебры полином $\Phi(z)$ степени p имеет p корней (возможно, комплексных). Это позволяет записать:

$$\Phi(L) = (1 - \lambda_1^{-1}L)(1 - \lambda_2^{-1}L) \dots (1 - \lambda_p^{-1}L),$$

где $\lambda_1, \dots, \lambda_p$ — корни $\Phi(z) = 0$. Стационарность AR(p) определяется расположением этих корней (подробнее в следующих сериях).

Обратный оператор. При $|\alpha| < 1$ оператор $(1 - \alpha L)$ обратим:

$$(1 - \alpha L)^{-1} = \sum_{k=0}^{\infty} \alpha^k L^k,$$

что совпадает с суммой бесконечно убывающей геометрической прогрессии. Если $|\alpha| \geq 1$, этот ряд расходится, и обратного оператора в таком виде не существует.

II.4 Процесс скользящего среднего — MA(q)

Определение.

$$y_t = \alpha_0 + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \beta_2 \varepsilon_{t-2} + \dots + \beta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim WN.$$

Это процесс скользящего среднего порядка q .

Содержательная интерпретация. Текущее значение ряда — взвешенная сумма текущего и прошлых случайных шоков. Смысл: в экономике происходят шоки, которые «суммируются» и «затухают» в течение q периодов. Интерпретировать MA-процессы несколько сложнее, чем AR, но они возникают естественно из теоремы Вольда (см. далее).

Свойства $MA(q)$.

$$\mathbb{E}[y_t] = \alpha_0,$$

$$D(y_t) = \sigma^2(1 + \beta_1^2 + \beta_2^2 + \dots + \beta_q^2) = \sigma^2 \sum_{j=0}^q \beta_j^2 \quad (\beta_0 = 1).$$

Это конечная сумма конечных слагаемых — константа.

Автоковариационная функция.

$$\gamma(k) = \text{cov}(y_t, y_{t-k}) = \begin{cases} \sigma^2 \sum_{j=0}^{q-k} \beta_j \beta_{j+k}, & 0 \leq k \leq q, \\ 0, & k > q. \end{cases}$$

Вывод формулы. Раскладываем y_t и y_{t-k} через ε . Ковариация двух ε равна σ^2 , если индексы совпадают, и 0 иначе. При $k \leq q$ некоторые ε входят в обе суммы — это и даёт ненулевой вклад.

Ключевое свойство: $\gamma(k)$ зависит только от k (не от t) и равна нулю при $k > q$ (автоковариация обрывается на лаге q).

$MA(q)$ всегда слабо стационарен. Из трёх пунктов выше: математическое ожидание, дисперсия и автоковариационная функция — все постоянны во времени. Таким образом, любой $MA(q)$ -процесс является слабо стационарным (при условии, что ε_t — белый шум).

II.5 Теорема Вольда (декомпозиция Вольда)


Любой слабо стационарный процесс $\{y_t\}$ может быть представлен в виде:

$$y_t = \alpha_0 + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j},$$

где: $\varepsilon_t \sim WN$, $\psi_0 = 1$, $\sum_{j=0}^{\infty} |\psi_j| < \infty$.

Иными словами, любой слабо стационарный процесс допускает представление $MA(\infty)$.

Случайное блуждание — пример нарушения условия теоремы. Для случайного блуждания сумма модулей коэффициентов бесконечна ($\sum |\psi_j| = \infty$). Это свидетельствует о нестационарности процесса.



Лекция III

AR-процессы: стационарность, ACF и PACF

III.1 Стационарность AR(p)-процесса

Ранее мы уже говорили о том, что MA-процессы — всегда слабо стационарные: у них постоянное (нулевое или константное) матожидание, постоянная дисперсия и автоковариационная функция, зависящая только от лага.

AR-процессы могут быть как стационарными, так и нестационарными:

$$y_t = \alpha y_{t-1} + \varepsilon_t,$$

процесс стационарен при $|\alpha| < 1$ и не стационарен при $|\alpha| \geq 1$.

Рассмотрим общий AR(p)-процесс (для простоты без константы, так как сдвиг на константу не влияет на стационарность):

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \varepsilon_t.$$

Ранее мы уже проверяли AR(1)-процесс на стационарность через подсчёт дисперсии и автоковариаций, но для AR(p) при $p \geq 2$ это неудобно.

Лаговый оператор и характеристическое уравнение. Перепишем процесс с помощью лагового оператора L ($Ly_t = y_{t-1}$):

$$(1 - \alpha_1 L - \alpha_2 L^2 - \dots - \alpha_p L^p) y_t = \varepsilon_t.$$

Если оператор $\Phi(L) = 1 - \alpha_1 L - \dots - \alpha_p L^p$ обратим, то

$$y_t = \Phi(L)^{-1} \varepsilon_t,$$

и получается представление $MA(\infty)$ с конечной суммой модулей коэффициентов, что гарантирует слабую стационарность (в силу теоремы Вольда).

Замечание III.1.1. Напоминание: для скаляра $|\alpha| < 1$ имеет место разложение

$$(1 - \alpha L)^{-1} = 1 + \alpha L + \alpha^2 L^2 + \alpha^3 L^3 + \dots$$

(сумма геометрической прогрессии). При $|\alpha| \geq 1$ такого ряда не существует.

III.1.1 Критерий стационарности

AR(p)-процесс слабо стационарен *тогда и только тогда*, когда все корни характеристического уравнения лежат строго внутри единичного круга:

$$|\lambda_i| < 1, \quad i = 1, 2, \dots, p.$$

Идея доказательства. Если все $|\lambda_i| < 1$, то каждый множитель $(1 - \lambda_i L)$ обратим, и

$$y_t = \prod_{i=1}^p (1 - \lambda_i L)^{-1} \varepsilon_t = \prod_{i=1}^p (1 + \lambda_i L + \lambda_i^2 L^2 + \dots) \varepsilon_t.$$

Это $MA(\infty)$ с коэффициентами, представляющими собой суммы произведений λ_i . Поскольку все $|\lambda_i| < 1$, коэффициенты при больших лагах сходятся к нулю, и сумма их модулей конечна. Значит, процесс стационарен.

Что происходит, если корень ≥ 1 по модулю. Допустим, есть корень λ_j такой, что $|\lambda_j| \geq 1$. Тогда мы можем представить процесс в виде

$$(1 - \lambda_j L)y_t = \varepsilon'_t,$$

где ε'_t — стационарный «более сложный шум», полученный из остальных множителей. Иначе говоря,

$$y_t = \lambda_j y_{t-1} + \varepsilon'_t.$$

Это специфичный $AR(1)$ с ошибкой ε'_t (не белым шумом, но стационарной).

- Если $|\lambda_j| = 1$ — получаем случайное блуждание (нестационарно: дисперсия растёт со временем).
- Если $|\lambda_j| > 1$ — получаем взрывной процесс (тоже нестационарен).

В обоих случаях процесс нестационарен. Достаточно одного «плохого» корня, чтобы стационарность не соблюдалась.

Две формы характеристического уравнения. Прямое характеристическое уравнение:

$$\lambda^p - \alpha_1 \lambda^{p-1} - \dots - \alpha_p = 0, \quad \text{условие стационарности: } |\lambda_i| < 1.$$

Обратное характеристическое уравнение (получается заменой $z = 1/\lambda$):

$$1 - \alpha_1 z - \alpha_2 z^2 - \dots - \alpha_p z^p = 0, \quad \text{условие стационарности: } |z_i| > 1.$$

То есть в первом случае требуется, чтобы корни были внутри единичного круга, а во втором — снаружи.

III.2 Автокорреляционная функция (ACF)

Определение. Для слабо стационарного процесса $\{y_t\}$:

$$\rho_k = \text{corr}(y_t, y_{t-k}) = \frac{\text{cov}(y_t, y_{t-k})}{D(y_t)} = \frac{\gamma_k}{\gamma_0},$$

где $\gamma_k = \text{cov}(y_t, y_{t-k})$ — автоковариация лага k , $\gamma_0 = D(y_t)$.

Запись $\rho_k = \gamma_k/\gamma_0$ корректна благодаря слабой стационарности: $D(y_t) = D(y_{t-k}) = \gamma_0$. Также из стационарности следует симметрия: $\rho_k = \rho_{-k}$.

АСФ для МА(q)-процесса

Для МА(q)-процесса $y_t = \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}$ автоковариации считаются «в лоб»:

$$\gamma_0 = \sigma^2(1 + \beta_1^2 + \dots + \beta_q^2), \quad \gamma_k = \begin{cases} \sigma^2 \sum_{i=0}^{q-k} \beta_i \beta_{i+k}, & 1 \leq k \leq q, \\ 0, & k > q. \end{cases}$$

(где $\beta_0 = 1$). Таким образом, ρ_k обнуляется при $k > q$.

АСФ для AR(p)-процесса

Попробуем посчитать автоковариации AR(p) напрямую. Возьмём

$$y_t = \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \varepsilon_t$$

и умножим на y_{t-1} , затем возьмём матожидание:

$$\gamma_1 = \alpha_1 \gamma_0 + \alpha_2 \gamma_1 + \alpha_3 \gamma_2 + \dots + \alpha_p \gamma_{p-1}.$$

Аналогично умножим на y_{t-2} :

$$\gamma_2 = \alpha_1 \gamma_1 + \alpha_2 \gamma_0 + \alpha_3 \gamma_1 + \alpha_4 \gamma_2 + \dots$$

Получается «ужасающее выражение γ_1 через саму себя и кучу других гамм». Прямой путь работает только для AR(1) и с трудом для AR(2). Нужна более систематическая техника — *уравнения Юла–Уокера*.

III.3 Уравнения Юла–Уокера

Вывод уравнений

Рассмотрим слабо стационарный AR(p) без константы:

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \varepsilon_t.$$

Замечание III.3.1. Из слабой стационарности и отсутствия константы следует $\mathbb{E}y_t = 0$. Действительно, после взятия матожидания получаем $\mathbb{E}y_t(1 - \alpha_1 - \dots - \alpha_p) = 0$, откуда $\mathbb{E}y_t = 0$ (если $\sum \alpha_i \neq 1$, иначе процесс не стационарен).

Шаг 1. Умножим уравнение на y_t и возьмём матожидание. Используем $\mathbb{E}y_t y_{t-k} = \gamma_k$ и $\mathbb{E}y_t \varepsilon_t = \sigma^2$ (т. к. в y_t присутствует ε_t с коэффициентом 1):

$$\gamma_0 = \alpha_1 \gamma_1 + \alpha_2 \gamma_2 + \dots + \alpha_p \gamma_p + \sigma^2.$$

Шаг 2. Умножим на y_{t-1} и возьмём матожидание ($\mathbb{E}y_{t-1} \varepsilon_t = 0$):

$$\gamma_1 = \alpha_1 \gamma_0 + \alpha_2 \gamma_1 + \dots + \alpha_p \gamma_{p-1}.$$

Шаг 3. Умножая на $y_{t-2}, y_{t-3}, \dots, y_{t-p}$, получаем аналогичные равенства. В общем виде:

$$\begin{aligned}\gamma_0 &= \alpha_1 \gamma_1 + \alpha_2 \gamma_2 + \dots + \alpha_p \gamma_p + \sigma^2, \\ \gamma_1 &= \alpha_1 \gamma_0 + \alpha_2 \gamma_1 + \dots + \alpha_p \gamma_{p-1}, \\ \gamma_2 &= \alpha_1 \gamma_1 + \alpha_2 \gamma_0 + \dots + \alpha_p \gamma_{p-2}, \\ &\vdots \\ \gamma_p &= \alpha_1 \gamma_{p-1} + \alpha_2 \gamma_{p-2} + \dots + \alpha_p \gamma_0.\end{aligned}$$

Это система $p + 1$ линейных уравнений с $p + 1$ неизвестными $\gamma_0, \gamma_1, \dots, \gamma_p$ (коэффициенты α_i известны из модели).

Решение системы

Перепишем систему в форме, удобной для применения метода Крамера:

$$\begin{aligned}\gamma_0 - \alpha_1 \gamma_1 - \alpha_2 \gamma_2 - \dots - \alpha_p \gamma_p &= \sigma^2, \\ -\alpha_1 \gamma_0 + \gamma_1 - \alpha_2 \gamma_1 - \dots &= 0, \\ &\vdots \\ -\alpha_p \gamma_0 - \alpha_{p-1} \gamma_1 - \dots + \gamma_p &= 0.\end{aligned}$$

Метод Крамера даёт каждую γ_j как отношение определителей: знаменатель — определитель основной матрицы, числитель — определитель той же матрицы, у которой j -й столбец заменён на столбец правых частей $(\sigma^2, 0, 0, \dots, 0)^\top$.

В частности, $\gamma_0 = D(y_t)$ — дисперсия AR(p)-процесса — находится без всяких ухищрений как одно из решений этой системы.

Рекуррентное соотношение для ρ_k при $k > p$

Если нужна автокорреляция большего порядка, чем p , не нужно решать новую систему. Достаточно домножить исходное уравнение на y_{t-p-1} :

$$\gamma_{p+1} = \alpha_1 \gamma_p + \alpha_2 \gamma_{p-1} + \dots + \alpha_p \gamma_1.$$

Поделив обе части на γ_0 , получаем удобное рекуррентное соотношение для автокорреляций:

$$\rho_k = \alpha_1 \rho_{k-1} + \alpha_2 \rho_{k-2} + \dots + \alpha_p \rho_{k-p}, \quad k > p.$$

Замечание III.3.2. Соотношение имеет ровно ту же форму, что и сам AR(p)-процесс, только для автокорреляций, поэтому, как только мы нашли $\rho_0, \rho_1, \dots, \rho_p$ через Юла–Уокера, все последующие значения вычисляются итерационно.

Сравнение MA и AR по виду ACF

MA(q): $\rho_k = 0$ при $k > q$ — ACF обрывается после лага q .

AR(p): ρ_k не обнуляется — затухает экспоненциально (или с осцилляциями).

Эта разница исторически использовалась для эмпирической идентификации модели по виду выборочной ACF.

III.4 Частная автокорреляционная функция (PACF)

Обычная АСФ ρ_k измеряет *суммарную* связь y_t и y_{t-k} , в которую входит как прямое влияние, так и опосредованное через промежуточные $y_{t-1}, y_{t-2}, \dots, y_{t-k+1}$.

Замечание III.4.1. Например, в $AR(1)$ корреляция между y_t и y_{t-10} ненулевая, но не потому, что y_{t-10} напрямую влияет на y_t , а потому, что $y_{t-10} \rightarrow y_{t-9} \rightarrow \dots \rightarrow y_t$ — влияние идёт по цепочке.

Чтобы выделить именно *прямое* влияние, очищенное от промежуточных лагов, вводится частная автокорреляционная функция.

Определение

PACF лага k — это корреляция y_t и y_{t-k} при условии фиксированных промежуточных значений:

$$\text{PACF}(k) = \text{corr}(y_t, y_{t-k} \mid y_{t-1}, y_{t-2}, \dots, y_{t-k+1}).$$

Вычисление через регрессию

Оценим линейную регрессию y_t на k предыдущих лагов:

$$y_t = \phi_{k,1}y_{t-1} + \phi_{k,2}y_{t-2} + \dots + \phi_{k,k}y_{t-k} + u_t.$$

Тогда PACF порядка k — это в точности коэффициент при последнем лаге:

$$\text{PACF}(k) = \phi_{k,k}.$$

В частности:

- $\phi_{1,1}$ — коэффициент в регрессии y_t на y_{t-1} ;
- $\phi_{2,2}$ — коэффициент при y_{t-2} в регрессии y_t на y_{t-1}, y_{t-2} ;
- и т. д.

Идея: проекция y_t на пространство $\{y_{t-1}, \dots, y_{t-k+1}\}$ даёт опосредованную часть, а ортогональный остаток — прямое влияние, которое и улавливает $\phi_{k,k}$.

Юла–Уокер для PACF

Чтобы найти $\phi_{k,k}$ теоретически, домножим уравнение регрессии последовательно на $y_{t-1}, y_{t-2}, \dots, y_{t-k}$ и возьмём матожидания. Получим систему:

$$\begin{aligned}\gamma_1 &= \phi_{k,1}\gamma_0 + \phi_{k,2}\gamma_1 + \dots + \phi_{k,k}\gamma_{k-1}, \\ \gamma_2 &= \phi_{k,1}\gamma_1 + \phi_{k,2}\gamma_0 + \dots + \phi_{k,k}\gamma_{k-2}, \\ &\vdots \\ \gamma_k &= \phi_{k,1}\gamma_{k-1} + \phi_{k,2}\gamma_{k-2} + \dots + \phi_{k,k}\gamma_0.\end{aligned}$$

Это k линейных уравнений с k неизвестными $\phi_{k,1}, \dots, \phi_{k,k}$ — автоковариации γ_i уже найдены на предыдущем этапе через Юла–Уокера для исходного процесса.

Используя метод Крамера, находим $\phi_{k,k}$ как отношение определителей:

$$\phi_{k,k} = \frac{\det P_k^*}{\det P_k},$$

где P_k — матрица автокорреляций (или автоковариаций) с элементами $\gamma_{|i-j|}$, а P_k^* — та же матрица, у которой последний столбец заменён на $(\gamma_1, \gamma_2, \dots, \gamma_k)^\top$.

Замечание III.4.2. На реальных данных оценка PACF тривиальна: достаточно запустить OLS-регрессию y_t на лагов $y_{t-1}, \dots, y_{t-k}$ и взять оценку коэффициента при y_{t-k} . Никаких сложных матричных вычислений руками делать не нужно.

Итоги лекции

1. AR(p) слабо стационарен $\iff$ все корни характеристического уравнения по модулю меньше 1 (или, в обратной форме, лежат вне единичного круга).
2. ACF для MA(q) обрывается после лага q ; для AR(p) — не обрывается, а затухает по рекуррентной формуле $\rho_k = \alpha_1 \rho_{k-1} + \dots + \alpha_p \rho_{k-p}$.
3. Уравнения Юла–Уокера — основной инструмент для нахождения автоковариаций AR(p). Это система линейных уравнений, решаемая методом Крамера.
4. PACF измеряет *прямое* влияние y_{t-k} на y_t при фиксированных промежуточных лагах. На практике: $\text{PACF}(k) = \phi_{k,k}$ — коэффициент при y_{t-k} в регрессии y_t на $y_{t-1}, \dots, y_{t-k}$.
5. ACF и PACF — две основные **диагностические функции** при работе с моделями временных рядов; для нестационарных процессов они теряют смысл (дают «дикий» вид — сигнал, что ряд не стационарен).



Лекция IV

Модели ARMA, ARIMA, SARIMA

В этой лекции углубляемся в семейство моделей ARMA: дополняем лаговый оператор, формализуем условия стационарности и обратимости, переходим к смешанным моделям ARMA(p, q), а затем к нестационарным обобщениям ARIMA, ARIMAX, ARFIMA и SARIMA.

IV.1 Лаговый оператор и формальная запись моделей

Лаговый оператор L действует на временной ряд по правилу:

$$L(x_t) \stackrel{\text{def}}{=} x_{t-1}, \quad L^2(x_t) = L(L(x_t)) = L(x_{t-1}) = x_{t-2}.$$

По индукции: $L^k(x_t) = x_{t-k}$, $k \in \mathbb{N}$. Формально полагают $L^0(x_t) = x_t$ — оператор без сдвига.

Замечание IV.1.1. Оператор L обладает свойствами обычного «множителя»: его можно складывать ($L+L^2$), умножать ($L \cdot L^2 = L^3$), раскладывать на множители. Для константы: $L(c) = c$.

Запись модели ARMA через лаговый оператор. Начнём сразу с общего вида модели ARMA(p, q):

$$x_t = \mu + \underbrace{\sum_{j=1}^p \phi_j x_{t-j}}_{\text{AR-часть}} + u_t + \underbrace{\sum_{s=1}^q \theta_s u_{t-s}}_{\text{MA-часть}}, \quad u_t \sim WN(0, \sigma_u^2), \quad \phi_p, \theta_q \neq 0.$$

Здесь μ — константа, связана со средним уровнем ряда; ϕ_j — коэффициенты AR-части (насколько прошлые значения влияют на текущее); θ_s — коэффициенты MA-части (насколько долго отголоски прошлых шоков остаются в ряду); u_t — текущий внешний шок (белый шум).

Замечание IV.1.2. Коэффициенты модели ARMA в общем случае не имеют экономической интерпретации — это просто параметры, наилучшим образом описывающие динамику ряда. Это отличает ARMA-модели от структурных эконометрических моделей.

Переписывая в операторной форме и вынося x_t за скобку:

$$\left(1 - \sum_{j=1}^p \phi_j L^j\right) x_t = \mu + \left(1 + \sum_{s=1}^q \theta_s L^s\right) u_t.$$

AR- и MA-полиномы. Введём два характеристических многочлена:

$$\phi(z) = 1 - \sum_{j=1}^p \phi_j z^j = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p,$$

$$\theta(z) = 1 + \sum_{s=1}^q \theta_s z^s = 1 + \theta_1 z + \theta_2 z^2 + \dots + \theta_q z^q.$$

Тогда модель ARMA записывается максимально компактно:

$$\phi(L) x_t = \mu + \theta(L) u_t.$$

Многочлен $\phi(z)$ имеет p корней, $\theta(z)$ — q корней (с учётом кратности, возможно — комплексных).

IV.2 ACF и PACF: различие AR и MA процессов

Напомним два инструмента из предыдущей лекции:

- *Автокорреляционная функция (ACF)* $\rho_k = \gamma_k / \gamma_0$ — измеряет суммарную силу связи между y_t и y_{t-k} , включая опосредованную через промежуточные значения.
- *Частная автокорреляционная функция (PACF)* $\phi_{kk} = \text{corr}(y_t, y_{t-k} \mid y_{t-1}, \dots, y_{t-k+1})$ — измеряет прямое влияние, очищенное от промежуточных лагов. Практически: ϕ_{kk} — последний коэффициент регрессии y_t на $y_{t-1}, \dots, y_{t-k}$.

ACF и PACF — это **диагностические инструменты** для идентификации модели:

- ACF «обрезается» на лаге $q \Rightarrow$ процесс похож на MA(q);
- PACF «обрезается» на лаге $p \Rightarrow$ процесс похож на AR(p).

IV.3 Авторегрессионные процессы AR(p)

Определение. $y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \varepsilon_t$, $\varepsilon_t \sim WN(0, \sigma^2)$.

Поведение PACF для AR(p). Рассмотрим, что произойдёт, если мы оценим регрессию с $k > p$ лагами:

$$y_t = \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \underbrace{\alpha_{p+1}}_{=0} y_{t-p-1} + \dots + \underbrace{\alpha_k}_{=0} y_{t-k} + \varepsilon_t.$$

Истинные коэффициенты при «лишних» лагах равны нулю — ведь процесс зависит только от p предыдущих значений. Следовательно:

$$\phi_{pp} = \alpha_p, \quad \text{PACF}(k) = \phi_{kk} = 0 \quad \forall k > p.$$

Вывод: PACF процесса AR(p) обрывается после лага p . Это и есть способ определить порядок p по графику PACF.

Рекуррентная форма АСФ для AR(p). Для самого процесса AR(p) автокорреляции удовлетворяют тому же рекуррентному соотношению, что и сам процесс:

$$\rho_k = \alpha_1 \rho_{k-1} + \alpha_2 \rho_{k-2} + \dots + \alpha_p \rho_{k-p}, \quad k \geq p.$$

Поэтому АСФ у AR(p) не обрывается, а плавно затухает (экспоненциально или с осцилляциями).

IV.4 Процессы скользящего среднего MA(q)

Определение.

$$y_t = \varepsilon_t + \beta_1 \varepsilon_{t-1} + \beta_2 \varepsilon_{t-2} + \dots + \beta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim WN.$$

В операторной форме: $y_t = (1 + \beta_1 L + \beta_2 L^2 + \dots + \beta_q L^q) \varepsilon_t$.

Свойство АСФ: у процесса MA(q) автокорреляции $\rho_k = 0$ при всех $k > q$ — АСФ обрывается на лаге q .

Обратимость МА-процесса. Это центральное понятие — отвечает на вопрос «можно ли по наблюдаемому ряду y_t восстановить ненаблюдаемые шоки ε_t ?».

Введём характеристический многочлен МА-полинома и его корни $\lambda_1, \dots, \lambda_q$:

$$\lambda^q + \beta_1 \lambda^{q-1} + \dots + \beta_q = 0 \implies \lambda_1, \lambda_2, \dots, \lambda_q.$$

Тогда МА-полином факторизуется:

$$y_t = (1 - \lambda_1 L)(1 - \lambda_2 L) \dots (1 - \lambda_q L) \varepsilon_t.$$

Условие обратимости. Если $|\lambda_j| < 1$ для всех j , то процесс называется *обратимым*, и его можно представить как $AR(\infty)$:

$$(1 - \lambda_1 L)^{-1} (1 - \lambda_2 L)^{-1} \dots (1 - \lambda_q L)^{-1} y_t = \varepsilon_t,$$

то есть $(1 - \alpha_1 L - \alpha_2 L^2 - \dots) y_t = \varepsilon_t \implies AR(\infty)$.

Замечание IV.4.1. Каждый из множителей раскладывается в ряд: $(1 - \lambda L)^{-1} = 1 + \lambda L + \lambda^2 L^2 + \dots$ при $|\lambda| < 1$. Этот ряд сходится только при $|\lambda| < 1$ — отсюда и условие обратимости.

Проблема неидентифицируемости. Если МА-процесс необратим, то метод максимального правдоподобия (ММП) даёт 2^q локальных максимумов — параметры определяются неоднозначно. Поэтому на практике рассматривают только обратимые МА-процессы.

Когда необратимость возникает «сама собой». Иногда необратимость появляется как побочный эффект преобразования. Например, пусть исходный ряд:

$$y_t = \alpha + \beta t + \varepsilon_t \quad (\text{линейный тренд}).$$

Если взять первую разность для устранения тренда:

$$\Delta y_t = y_t - y_{t-1} = \beta + \underbrace{\varepsilon_t - \varepsilon_{t-1}}_{\text{это уже МА(1) с } \beta_1 = -1}.$$

Корень $\lambda_1 = 1$, то есть $|\lambda_1| = 1$ — процесс не обратим. Это и есть тот самый случай «когда необратимость — это плохо»: применили лишнюю разность к тренд-стационарному ряду и получили неприятную МА-структуру.

IV.5 Смешанные модели ARMA(p, q)

Процесс ARMA(p, q).

$$y_t = \alpha_0 + \underbrace{\alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p}}_{\text{AR-часть}} + \underbrace{\varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}}_{\text{MA-часть (всегда стационарна)}}.$$

Условие стационарности через корни AR-полинома. Модель ARMA задаёт стационарный ряд *тогда и только тогда*, когда все корни (в том числе из $\mathbb{C}$) AR-многочлена $\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$ по модулю больше единицы — то есть лежат вне единичного круга на комплексной плоскости.

Замечание IV.5.1. Симметрия с обратимостью. Полная картина:

- Стационарность ARMA $\iff$ корни AR-полинома $\phi(z)$ лежат вне единичного круга ($|z_j| > 1$).
- Обратимость ARMA $\iff$ корни MA-полинома $\theta(z)$ лежат вне единичного круга ($|z_j| > 1$).

Оба условия — про корни, и оба — «вне единичного круга», когда мы говорим о z . Если же говорить про корни λ в форме $\prod(1 - \lambda_j L)$, то условие наоборот — $|\lambda_j| < 1$, потому что $\lambda_j = 1/z_j$.

Пример: ARMA(1, q). Рассмотрим модель

$$x_t = \mu + \phi x_{t-1} + u_t + \sum_{s=1}^q \theta_s u_{t-s}, \quad \phi, \theta_q \neq 0.$$

AR-полином: $\phi(z) = 1 - \phi z$, единственный корень: $z_0 = 1/\phi$. Условие стационарности $|z_0| > 1$ эквивалентно $|\phi| < 1$:

$$\text{ARMA}(1, q) \text{ стационарна} \iff |\phi| < 1.$$

Пример: AR(1) и интуиция. Чтобы понять, почему условие $|\phi| < 1$ так важно, рассмотрим модель $x_t = \phi x_{t-1} + u_t$ и «раскрутим» её назад:

$$\begin{aligned} x_t &= \phi(\phi x_{t-2} + u_{t-1}) + u_t = \phi^2 x_{t-2} + \phi u_{t-1} + u_t \\ &= \phi^3 x_{t-3} + \phi^2 u_{t-2} + \phi u_{t-1} + u_t \\ &\vdots \\ &= \phi^k x_{t-k} + \sum_{j=0}^{k-1} \phi^j u_{t-j}. \end{aligned}$$

Что происходит при $k \rightarrow \infty$?

- Если $|\phi| < 1$: $\phi^k \rightarrow 0$ — вклад далёкого прошлого исчезает, ряд стационарен.
- Если $|\phi| = 1$: ϕ^k не убывает — все прошлые шоки имеют одинаковый вес, ряд нестационарен (это случайное блуждание).
- Если $|\phi| > 1$: $\phi^k \rightarrow \infty$ — вклад прошлого даже усиливается, ряд «взрывается».

Среднее значение стационарного ARMA. Для стационарного ARMA $\mathbb{E}x_t = \text{const}$ (не зависит от t) и $\mathbb{E}u_s = 0$. Возьмём матожидание от обеих частей:

$$\mathbb{E}x_t = \mu + \sum_{j=1}^p \phi_j \mathbb{E}x_{t-j}.$$

Так как $\mathbb{E}x_{t-j} = \mathbb{E}x_t$:

$$\left(1 - \sum_{j=1}^p \phi_j\right) \mathbb{E}x_t = \mu \implies \mathbb{E}x_t = \frac{\mu}{1 - \sum_{j=1}^p \phi_j} = \frac{\mu}{\phi(1)}.$$

Заметим, что $1 - \sum_j \phi_j = \phi(1)$ — значение AR-полинома в точке $z = 1$.

Замечание IV.5.2. *Что если $\sum \phi_j = 1$? Тогда $\phi(1) = 0$, и формула $\mathbb{E}x_t = \mu/\phi(1)$ не существует — деление на ноль. Это в точности означает, что $z = 1$ является корнем AR-полинома, и условие стационарности нарушено. Среднего значения у такого ряда просто нет — это случай единичного корня (например, случайное блуждание $x_t = x_{t-1} + u_t$).*

Представление стационарного ARMA как $MA(\infty)$. Стационарный $ARMA(p, q)$ можно представить как модель скользящего среднего бесконечного порядка:

$$x_t = \mu_1 + u_t + \sum_{j=1}^{\infty} \psi_j u_{t-j},$$

где коэффициенты ψ_j определяются через формальное деление многочленов:

$$\frac{\theta(z)}{\phi(z)} = 1 + \sum_{j=1}^{\infty} \psi_j z^j.$$

Из $\phi(L)x_t = \mu + \theta(L)u_t$ при условии стационарности оператор $\phi(L)$ обратим, и:

$$x_t = \phi(L)^{-1} \mu + \frac{\theta(L)}{\phi(L)} u_t = \mu_1 + \left(1 + \sum_{j=1}^{\infty} \psi_j L^j\right) u_t,$$

где $\mu_1 = \mu/\phi(1)$ — среднее значение.


Важное следствие. Для стационарной ARMA:

$$\text{cov}(u_t, x_{t-h}) = 0 \text{ при всех } h > 0,$$

то есть внешний шок не коррелирует с прошлыми значениями ряда.

Замечание IV.5.3. *Это важно для эконометрики: текущий шок u_t — это «новость», которая ещё не отразилась в прошлом. Прошлые значения x_{t-h} зависят только от прошлых шоков $u_{t-h}, u_{t-h-1}, \dots$, и поэтому ортогональны u_t — что и нужно для состоятельности ОЛС-оценок.*

Иллюстрация: траектория ARMA(1,1) с $\phi = -0,8$.



При $\phi = -0,8$ траектория сильно осциллирует (отрицательная автокорреляция первого порядка — после высоких значений идут низкие). На ACF будет ярко выраженная отрицательная корреляция на лаге 1 с последующими затухающими колебаниями.

Идентификация модели по ACF и PACF.

Процесс	ACF	PACF
AR(p)	плавно затухает	обрывается на лаге p
MA(q)	обрывается на q	плавно затухает
ARMA(p, q)	плавно затухает	плавно затухает

Интуиция: поскольку ARMA содержит и AR-часть, и MA-часть, ни ACF, ни PACF не обрываются полностью — обе функции плавно затухают. Это и осложняет визуальную идентификацию порядка ARMA-моделей.

IV.6 Нестационарные процессы

Все рассмотренные выше модели (AR, MA, ARMA) подходят только для стационарных рядов. Если ряд имеет тренд или единичный корень — нужно сначала привести его к стационарному виду. Существует две принципиально разные стратегии:

- **TS:** trend stationary (трендово стационарный);
- **DS:** difference stationary (разностно стационарный).

IV.6.1 Trend Stationary (TS) процессы

Процесс является *trend stationary*, если он становится стационарным после вычитания (детерминированного) тренда:

$$y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \dots + \alpha_k t^k + \varepsilon_t.$$

Стратегия работы с TS:

1. Оцениваем тренд: $\hat{y}_t = \hat{\alpha}_0 + \hat{\alpha}_1 t + \dots + \hat{\alpha}_k t^k$.
2. Вычитаем: $y_t - \hat{y}_t = \hat{\varepsilon}_t$ — этот ряд стационарен.

Замечание IV.6.1. Можно «по ошибке» взять разность вместо вычитания тренда — но тогда получится необратимый MA-процесс (см. выше). Это типичный случай переразностной обработки (over-differencing).

IV.6.2 Difference Stationary (DS) процессы

Процесс является *difference stationary*, если он становится стационарным после взятия разности (одной или нескольких). Простейший пример — случайное блуждание:

$$y_t = y_{t-1} + \varepsilon_t.$$

Оператор разности: $\Delta = 1 - L$. Тогда:

$$\Delta y_t = (1 - L)y_t = y_t - y_{t-1}.$$

Для случайного блуждания: $\Delta y_t = \varepsilon_t$ — белый шум, стационарен.

IV.6.3 Интегрированные процессы I(d)

Процесс называется *интегрированным порядка d* ($y_t \sim I(d)$), если он становится стационарным после d -кратного применения оператора разности:

$$\Delta^d y_t = \varepsilon_t \text{ — стационарен.}$$

Высшие степени оператора разности: $\Delta^d = (1 - L)^d$. Например:

$$\Delta^2 = (1 - L)^2 = 1 - 2L + L^2, \quad \Delta^2 y_t = y_t - 2y_{t-1} + y_{t-2}.$$

Замечание IV.6.2. *Стационарный процесс — это $I(0)$. Случайное блуждание — $I(1)$. Если ряд имеет два единичных корня (например, накопленное случайное блуждание) — $I(2)$.*

IV.7 ARIMA(p, d, q)

Идея: к ряду y_t применяется d -кратная разность для устранения нестационарности, а к полученному стационарному ряду $\Delta^d y_t$ применяется модель ARMA(p, q):

$$\Delta^d y_t = \alpha_1 \Delta^d y_{t-1} + \cdots + \alpha_p \Delta^d y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \cdots + \beta_q \varepsilon_{t-q}.$$

Параметры: p — порядок AR, d — порядок интеграции, q — порядок MA.

IV.8 ARIMAX(p, d, q)

Расширение ARIMA, в котором добавлены экзогенные регрессоры $x_{1t}, \dots, x_{Kt}$:

$$\Delta^d y_t = \alpha_1 \Delta^d y_{t-1} + \cdots + \alpha_p \Delta^d y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \cdots + \beta_q \varepsilon_{t-q} + \gamma_1 x_{1t} + \cdots + \gamma_K x_{Kt}.$$

Буква X в названии — от *eXogenous*.

Замечание IV.8.1. Внимание! Все экзогенные регрессоры x_{kt} должны быть стационарны. Если регрессор x_{kt} имеет ту же интеграцию, что и y_t , то его тоже нужно продифференцировать.

IV.9 ARFIMA(p, d, q)

ARFIMA — AutoRegressive Fractionally Integrated Moving Average. Отличие от ARIMA: параметр d может быть *дробным* (не целым), $d \in \mathbb{R}$. Используется представление $FI(d)$ (Fractionally Integrated):

$$(1 - L)^d y_t = \varepsilon_t, \quad d \in \mathbb{R}.$$

Замечание IV.9.1. *Зачем нужно дробное d ? ARFIMA позволяет моделировать ряды с долгой памятью (long memory) — когда автокорреляции затухают медленнее, чем экспоненциально (по степенному закону), но быстрее, чем у нестационарного процесса. Дробная разность $(1 - L)^d$ при $0 < d < 0,5$ как раз даёт стационарный процесс с такой долгой памятью.*

Раскладывается через биномиальный ряд:

$$(1 - L)^d = \sum_{k=0}^{\infty} \binom{d}{k} (-L)^k = 1 - dL + \frac{d(d-1)}{2!} L^2 - \frac{d(d-1)(d-2)}{3!} L^3 + \dots$$

IV.10 SARIMA: учёт сезонности

SARIMA (Seasonal ARIMA) — добавляет к ARIMA сезонную компоненту. Параметры $SARIMA(p, d, q) \times (P, D, Q)_s$:

- (p, d, q) — несезонные порядки (как в обычной ARIMA);
- (P, D, Q) — сезонные порядки AR, интеграции и MA;
- s — длина сезонного цикла (число наблюдений в одном цикле): для месячных данных $s = 12$, для квартальных $s = 4$, для дневных с недельной сезонностью $s = 7$.

Сезонный оператор разности:

$$\Delta_s^D = (1 - L^s)^D.$$

Например, $\Delta_{12} y_t = y_t - y_{t-12}$ устраняет годовую сезонность для месячных данных.

Полная запись модели:

$$\begin{aligned} \Delta^d \Delta_s^D y_t &= \alpha_1 \Delta^d \Delta_s^D y_{t-1} + \dots + \alpha_p \Delta^d \Delta_s^D y_{t-p} \\ &+ \alpha_1^s \Delta^d \Delta_s^D y_{t-s} + \dots + \alpha_P^s \Delta^d \Delta_s^D y_{t-P \cdot s} \\ &+ \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q} \\ &+ \beta_1^s \varepsilon_{t-s} + \dots + \beta_Q^s \varepsilon_{t-s \cdot Q}. \end{aligned}$$


Замечание IV.10.1. *Идея SARIMA в одной фразе: мы берём «обычные» лаги $(1, 2, \dots, p)$ и «сезонные» лаги $(s, 2s, \dots, P \cdot s)$ — и применяем к ним AR, MA и разности независимо. Это позволяет моделировать ряды, где наблюдается и трендовая, и сезонная структура (например, продажи мороженого по месяцам).*

IV.11 Итоговая схема классификации моделей

Модель	Назначение / структура
AR(p)	Стационарный, зависит от p предыдущих значений ряда
MA(q)	Стационарный, зависит от q предыдущих шоков
ARMA(p, q)	Стационарный, объединяет AR и MA
ARIMA(p, d, q)	ARMA на d -й разности (для DS-процессов)
ARIMAX(p, d, q)	ARIMA + экзогенные регрессоры
ARFIMA(p, d, q)	ARIMA с дробным d (длинная память)
SARIMA	ARIMA с сезонной компонентой

Алгоритм построения модели для временного ряда (методология Бокса–Дженкинса):

1. Проверить ряд на стационарность (графически и тестами на единичный корень: ADF, KPSS).
2. Если ряд нестационарен — взять разность нужного порядка d (и/или сезонную D).
3. Построить ACF и PACF преобразованного ряда.
4. Идентифицировать p и q по поведению PACF и ACF.
5. Оценить параметры (ОЛС, ММП).
6. Проверить остатки на белый шум (тест Льюнга–Бокса).
7. Сравнить альтернативные модели по AIC/BIC, выбрать лучшую.



Лекция V

Тесты на единичные корни и процедура Бокса–Дженкинса

V.1 Тесты на единичные корни

Рассмотрим авторегрессионный процесс первого порядка $AR(1)$:

$$y_t = \alpha y_{t-1} + \varepsilon_t.$$

Проверяемая гипотеза о наличии единичного корня:

$$H_0 : |\alpha| = 1, \quad H_1 : |\alpha| < 1.$$

Замечание V.1.1. Общий случай. Тесты на единичные корни в общем случае проводятся для характеристического уравнения. Пусть $\lambda_1, \dots, \lambda_p$ — корни характеристического уравнения процесса $AR(p)$. Тогда

$$H_0 : \exists j : |\lambda_j| = 1, \quad H_1 : \forall j : |\lambda_j| < 1.$$

V.1.1 Тест Дики–Фуллера (Dickey–Fuller)

Исходное уравнение $AR(1)$:

$$y_t = \alpha y_{t-1} + \varepsilon_t.$$

Вычтем из обеих частей y_{t-1} :

$$\Delta y_t = (\alpha - 1) y_{t-1} + \varepsilon_t.$$

Обозначив $\beta = \alpha - 1$, получаем оцениваемое уравнение:

$$\widehat{\Delta y_t} = \widehat{\beta} y_{t-1} + \varepsilon_t.$$

Гипотезы теста:

$$H_0 : \beta = 0, \quad H_1 : \beta < 0.$$

Статистика теста строится как обычное t -отношение:

$$t = \frac{\widehat{\beta}}{\sqrt{\widehat{D}(\widehat{\beta})}}.$$

Замечание V.1.2. Важно. Эта статистика не имеет распределения Стьюдента. Она подчиняется специальному DF-распределению (*DF test distribution*), для которого используются собственные (нестандартные) критические значения.

V.1.2 Спецификации DF-теста

DF-тест может проводиться в трёх спецификациях. Их проверяют *итеративно* (в «старомодном» подходе — по очереди: без всего, с константой, с константой и трендом).

1) **Без константы и тренда:**

$$\Delta y_t = \beta y_{t-1} + u_t, \quad H_0 : RW.$$

2) **С константой:**

$$\Delta y_t = \alpha + \beta y_{t-1} + u_t, \quad H_0 : RWD.$$

3) **С константой и трендом:**

$$\Delta y_t = \alpha_0 + \alpha_1 t + \beta y_{t-1} + u_t, \quad H_0 : RWD + T.$$

Нулевые гипотезы в развёрнутом виде:

$$RW : y_t = y_{t-1} + \varepsilon_t,$$

$$RWD : y_t = y_{t-1} + \alpha + u_t,$$

$$RWD + T : y_t = y_{t-1} + \alpha_0 + \alpha_1 t + u_t.$$

Здесь RW — случайное блуждание, RWD — случайное блуждание со сдвигом, $RWD + T$ — случайное блуждание со сдвигом и трендом (стационарный AR за счёт трендовой части).

V.1.3 Расширенный тест Дики–Фуллера (ADF)

Augmented Dickey–Fuller test позволяет оценивать процессы $AR(p)$. Оцениваемое уравнение:

$$\Delta y_t = \beta y_{t-1} + \alpha_1 \Delta y_{t-1} + \dots + \alpha_k \Delta y_{t-k} + u_t.$$

Вывод для $AR(2)$. Рассмотрим процесс

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + u_t.$$

Вычтем y_{t-1} :

$$\Delta y_t = (\alpha_1 - 1) y_{t-1} + \alpha_2 y_{t-2} + u_t.$$

Прибавим и вычтем $\alpha_2 y_{t-1}$:

$$\Delta y_t = (\alpha_1 - 1) y_{t-1} + \alpha_2 y_{t-1} - \alpha_2 y_{t-1} + \alpha_2 y_{t-2} + u_t.$$

Сгруппировав слагаемые, получаем:

$$\Delta y_t = (\alpha_2 + \alpha_1 - 1) y_{t-1} - \alpha_2 \Delta y_{t-1} + u_t.$$

Замечание V.1.3. Интерпретация. Если сумма коэффициентов $\alpha_1 + \alpha_2 = 1$, то процесс $AR(2)$ имеет единичный корень (это также можно проверить через корни характеристического уравнения).

Гипотезы и статистика теста:

$$H_0 : \beta = 0, \quad H_1 : \beta < 0,$$

$$\frac{\hat{\beta}}{\sqrt{\hat{D}(\hat{\beta})}} \stackrel{H_0}{\approx} ADF_{\text{stat}}.$$

В DF/ADF-тестах альтернатива *всегда односторонняя*. Количество лагов также подбирается (проверяется) в рамках ADF.

V.1.4 Другие тесты на стационарность

Тест Филлипса–Перрона (PP test). Аналог ADF, но с другим способом подсчёта статистики. Менее параметрический: не требует нормальности шума.

Тест KPSS. Гипотезы заданы «наоборот» относительно DF/ADF:

$$H_0 : \text{ряд стационарный}, \quad H_1 : \text{ряд нестационарный}.$$

Сравнение тестов. Тесты обладают разными свойствами в плане устойчивости к выбросам, сезонным корректировкам, логарифмированию.

- **KPSS** — самый устойчивый, но менее мощный.
- **ADF** — самый мощный.

На практике лучше проводить все три теста.

V.2 Процедура Бокса–Дженкинса (Box–Jenkins)

Процедура Бокса–Дженкинса — это подбор оптимальной модели $ARIMA(p, d, q)$ для ряда y_t . Требуется определить три параметра:

$$p-?, \quad d-?, \quad q-?$$

Шаги 1 и 2 — идентификация модели $ARIMA$, шаг 3 — её оценивание.

V.2.1 Шаг 1. Определение порядка интегрирования d

Параметр d — количество разностей, которое нужно взять, чтобы ряд стал стационарным (то есть чтобы исчезли единичные корни). Алгоритм итеративный:

$$y_t \xrightarrow{ADF} \begin{cases} \text{стационарен} \Rightarrow d = 0, \\ \text{нестационарен} \Rightarrow \Delta y_t \xrightarrow{ADF} \begin{cases} \text{стац.} \Rightarrow d = 1, \\ \text{нестаци.} \Rightarrow \Delta^2 y_t \xrightarrow{ADF} \dots \end{cases} \end{cases}$$

V.2.2 Шаг 2. Определение порядков p и q

Для уже продифференцированного ряда $\Delta^d y_t$ строят автокорреляционную функцию (ACF) и частную автокорреляционную функцию (PACF).

- Порядок q определяют по графику **ACF**: ищут лаг, после которого значения «обрываются» (становятся незначимыми). На графике ACF из конспекта обрыв происходит после третьего лага $\Rightarrow q = 3$.
- Порядок p определяют по графику **PACF** аналогично: ищут наибольший «скачок» между значимыми и незначимыми столбиками. В конспекте $\Rightarrow p = 2$.

Замечание V.2.1. p и q подбираются «методом пристального взгляда»: смотрят, где наибольший скачок между столбиками (между значимым и незначимым значением). Тесты ниже нужны для проверки значимости.

Тесты на значимость автокорреляций. Проверяемая гипотеза:

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_n = 0.$$

- **Box–Pierce test** — статистика $T \sum_{k=1}^n \hat{\rho}_k^2$.
- **Ljung–Box test** — уточнённая статистика $T(T+2) \sum_{k=1}^n \hat{\rho}_k^2 / (T-k)$.

V.2.3 Шаг 3. Оценивание модели ARIMA

Модель связывает $\Delta^d y_t$ с её собственными лагами и лагами ошибок:

$$\Delta^d y_t \sim \underbrace{\Delta^d y_{t-1}, \dots, \Delta^d y_{t-p}}_{\text{есть «цифры» (наблюдаемые)}}, \quad \underbrace{\varepsilon_{t-1}, \dots, \varepsilon_{t-q}}_{\text{нет «цифр» (ненаблюдаемые)}}.$$

Проблема ненаблюдаемых ошибок. Поскольку прошлые ошибки ненаблюдаемы, делается предположение о нулевых «старых» ошибках:

$$\begin{aligned} \varepsilon_1 &= \Delta^d y_1 - \alpha_1 \Delta^d y_{t-1} - \dots - \alpha_p \Delta^d y_{t-p} - 0 - \dots - 0, \\ \varepsilon_2 &= \dots - \beta_1 \varepsilon_1 - 0 - \dots - 0. \end{aligned}$$

Способы оценивания.

- 1) Оценка модифицированным МНК (заменяя ε_{t-1} на $\hat{\varepsilon}_{t-1}$).
- 2) Фильтр Калмана.
- 3) GMM (обобщённый метод моментов).
- 4) Байесовский подход.

Метод максимального правдоподобия (ML). Самый «правильный» подход. Ошибки выражаются через наблюдаемые величины:

$$\varepsilon_t = \Delta^d y_t - \alpha_1 \Delta^d y_{t-1} - \cdots - \alpha_p \Delta^d y_{t-p} - \beta_1 \varepsilon_{t-1} - \cdots - \beta_q \varepsilon_{t-q}.$$

Предполагается совместная нормальность вектора ошибок:

$$\begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_t \end{pmatrix} \sim N(0, V),$$

где V — ковариационная матрица (формируется по МА-части модели).

V.2.4 Информационные критерии

Более современный подход к отбору модели — использование информационных критериев.

Критерий Акаике (Akaike Info Criterion, AIC):

$$AIC = 2k - 2 \ln \hat{L}.$$

Критерий Шварца (Schwartz IC, он же Bayesian IC, BIC):

$$SIC/BIC = k \ln T - 2 \ln \hat{L}.$$


Обозначения:

- k — число всех оцениваемых коэффициентов модели, $k = p + q$;
- T — количество наблюдений;
- $\hat{L}$ — функция правдоподобия.

По природе оба критерия — *штрафы*: чем меньше значение, тем лучше модель. Значения лежат в $(-\infty, +\infty)$ и растут с увеличением числа коэффициентов.

Свойства при отборе моделей. AIC — эффективность. Если истинной модели нет в множестве рассматриваемых, AIC отбирает наиболее близкую к истинной.

BIC — состоятельность. Сильнее штрафует за лишние коэффициенты $\Rightarrow$ меньше риск переобучения (*overfit*). Если истинная модель есть в множестве рассматриваемых, BIC её отбирает.



Лекция VI

Прогнозирование по ARIMA и многомерные модели

VI.1 Прогнозирование по ARIMA

Рассмотрим модель $ARIMA(p, 1, q)$ — с интегрированием первого порядка:

$$\Delta y_t = \alpha_0 + \alpha_1 \Delta y_{t-1} + \dots + \alpha_p \Delta y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}.$$

Это $ARMA(p, q)$, применённый не к самому ряду y_t , а к его *разностям* $\Delta y_t = y_t - y_{t-1}$. Параметр $d = 1$ означает «однократно проинтегрированный» процесс. Для прогноза удобнее перейти от разностей обратно к уровням y_t .

Переход к уровням

Подставляем $\Delta y_t = y_t - y_{t-1}$:

$$y_t - y_{t-1} = \alpha_0 + \alpha_1 (y_{t-1} - y_{t-2}) + \dots + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots$$

После перегруппировки:

$$y_t = \alpha_0 + (1 + \alpha_1) y_{t-1} + (\alpha_2 - \alpha_1) y_{t-2} + \dots + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q}.$$

Получилось обычное уравнение для уровней с пересчитанными коэффициентами. Теперь можно строить прогноз $\hat{y}_{t+h|t}$ — прогноз y_{t+h} , сделанный в момент t .

Прогноз на один шаг вперёд

Для момента $t + 1$:

$$y_{t+1|t} = \alpha_0 + (1 + \alpha_1) y_t + \dots + \underbrace{\varepsilon_{t+1}}_{\mathbb{E}(\varepsilon_{t+1})=0} + \beta_1 \varepsilon_t + \dots$$

Будущая ошибка ε_{t+1} нам неизвестна — в прогноз подставляется её ожидание, 0. Используя оценки коэффициентов:

$$\hat{y}_{t+1|t} = \hat{\alpha}_0 + (1 + \hat{\alpha}_1) y_t + \dots + \hat{\beta}_1 \varepsilon_t + \dots$$

Прогноз на несколько шагов вперёд

При прогнозе на $h = 2$:

$$\hat{y}_{t+2|t} = \hat{\alpha}_0 + (1 + \hat{\alpha}_1) \hat{y}_{t+1|t} + \dots + \underbrace{\hat{\beta}_1 \cdot 0}_{\mathbb{E}(\varepsilon_{t+1})=0} + \hat{\beta}_2 \varepsilon_t + \dots$$

Прогноз строится итеративно: y_{t+1} прогнозируется по y_t , y_{t+2} — по уже спрогнозированному $\hat{y}_{t+1|t}$ и так далее. Будущие ошибки везде заменяются нулями, прошлые ошибки берутся из остатков модели.

При $h > q$ МА-часть «выдыхается». Все прошлые ошибки уже использованы — остаются только AR-члены:


$$\hat{y}_{t+h|t} = \hat{\alpha}_0 + (1 + \hat{\alpha}_1) \hat{y}_{t+h-1|t} + \dots \quad (\beta \text{ не будет}).$$

Замечание VI.1.1. Качественное поведение прогноза.

- Для **стационарного** ряда прогноз быстро возвращается к константе (среднему уровню ряда).
- Для **нестационарного** ряда прогноз продолжает двигаться вместе с трендом.

Если горизонт прогноза $h > \max(p, q)$, то обычно прогноз — это либо константа, либо тренд.

Практическое правило. ARIMA хорошо строит прогнозы на 2–3 шага вперёд. На большем горизонте можно, но не особо полезно — модель теряет информативность.



VI.2 Доверительные интервалы для прогноза

Прогноз — это случайная величина. Его дисперсия складывается из *двух источников*:

1. неопределённость оценок коэффициентов $\hat{\alpha}, \hat{\beta}$;
2. неопределённость будущих ошибок ε .

Общая формула дисперсии прогноза

$$D(\hat{y}_{t+1|t}) = D(\hat{\alpha}_0 + (1 + \hat{\alpha}_1) y_t + \dots + \hat{\beta}_1 \varepsilon_t + \dots).$$

Раскрывая (с учётом ковариаций между оценками):

$$D(\hat{y}_{t+1|t}) = D(\hat{\alpha}_0) + y_t^2 D(\hat{\alpha}_1) + \dots + y_t \operatorname{cov}(\hat{\alpha}_0, \hat{\alpha}_1) + \dots + \sigma_\varepsilon^2.$$

Первая часть — дисперсия линейной комбинации оценок коэффициентов (зависит от значений y, ε и ковариационной матрицы оценок). Вторая — собственная дисперсия будущего шока ε_{t+1} , она равна σ_ε^2 :

$$D(\hat{y}_{t+1|t}) = \hat{D}(\dots) + \sigma_\varepsilon^2.$$

Пример: AR(1)

Рассмотрим простую модель $\hat{y}_t = \hat{\alpha} y_{t-1}$. Прогнозы на разные горизонты:

$$\begin{aligned}\hat{y}_{t+1|t} &= \alpha y_t + \varepsilon_{t+1}, \\ \hat{y}_{t+2|t} &= \alpha^2 y_t + \alpha \varepsilon_{t+1} + \varepsilon_{t+2}, \\ \hat{y}_{t+3|t} &= \alpha^3 y_t + \alpha^2 \varepsilon_{t+1} + \alpha \varepsilon_{t+2} + \varepsilon_{t+3}.\end{aligned}$$

На каждом шаге появляется новый шок плюс «отголоски» предыдущих шоков, помноженные на степени α . Чем дальше горизонт, тем больше слагаемых, и каждое из них ещё умножается на квадрат степени α в дисперсии.


Дисперсии прогнозов:

$$\begin{aligned}D(\hat{y}_{t+1|t}) &= \hat{D}(\hat{\alpha}) y_t^2 + \sigma^2, \\ D(\hat{y}_{t+2|t}) &= \hat{D}(\hat{\alpha}^2) y_t^2 + \hat{D}(\hat{\alpha}) \sigma^2 + \sigma^2, \\ D(\hat{y}_{t+3|t}) &= \hat{D}(\hat{\alpha}^3) y_t^2 + \hat{D}(\hat{\alpha}^2) \sigma^2 + \hat{D}(\hat{\alpha}) \sigma^2 + \sigma^2.\end{aligned}$$

Замечание VI.2.1. Главный вывод. Дисперсия прогноза растёт с горизонтом прогнозирования. Это и есть формальное обоснование того, почему дальние прогнозы менее надёжны.

Fan chart

Графически результат выглядит как **веер** (fan chart): доверительный интервал расширяется по мере удаления от настоящего момента. Внутри «веера» закрашивают зоны разных доверительных уровней (50 %, 80 %, 95 %) — отсюда и название. Используется в отчётах центробанков (Банк Англии популяризировал такой способ изображения прогнозов инфляции).



Fan chart: доверительный интервал расширяется с ростом горизонта прогноза.

VI.3 Многомерные модели

В реальности на y_t могут влиять и *другие* ряды x_t . Чтобы это учесть, в модель добавляют экзогенные переменные.

VI.3.1 Модель ARIMAX

ARIMAX = ARIMA + exogenous variables: расширение ARIMA, в котором правую часть дополняют внешние регрессоры:

$$\Delta^d y_t = \alpha_0 + \alpha_1 \Delta^d y_{t-1} + \dots + \gamma_1 x_{1t} + \dots + \gamma_k x_{kt}.$$

Проверка значимости экзогенной переменной.

$$H_0 : \gamma_1 = 0, \quad H_1 : \gamma_1 \neq 0.$$

Если гипотеза H_0 отвергается, переменная x_1 значимо влияет на y .

VI.3.2 Пример: AR(1) с внешним регрессором

Предположим $|\alpha_1| < 1$ (ряд стационарен). Модель:

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \gamma x_t + \varepsilon_t.$$

Допустим, оценили $\gamma = 5$. Как реакция y распространяется во времени?

Мгновенный эффект.

$$\frac{\partial y_t}{\partial x_t} = \gamma = 5.$$

Эффект через один период. В уравнении $y_{t+1} = \alpha_0 + \alpha_1 y_t + \gamma x_{t+1} + \varepsilon_{t+1}$ переменная x_t входит только через y_t :

$$\frac{\partial y_{t+1}}{\partial x_t} = \alpha_1 \cdot \frac{\partial y_t}{\partial x_t} = \alpha_1 \cdot 5.$$

Эффект через два периода.

$$\frac{\partial y_{t+2}}{\partial x_t} = \alpha_1 \cdot \frac{\partial y_{t+1}}{\partial x_t} = \alpha_1^2 \cdot 5.$$

В общем виде:


$$\frac{\partial y_{t+h}}{\partial x_t} = \alpha_1^h \cdot \gamma.$$

Шок в x_t распространяется по цепочке: сначала меняет y_t , потом y_{t+1} через AR-член $\alpha_1 y_t$, потом y_{t+2} через $\alpha_1 y_{t+1}$ и т. д. Каждый шаг даёт дополнительный множитель α_1 .

Замечание VI.3.1. Импульсный отклик (Impulse Response Function, *IRF*) — зависимость $\partial y_{t+h} / \partial x_t$ от горизонта h .

Поведение зависит от знака α_1 :

- $\alpha_1 > 0$ — *IRF* монотонно затухает (экспоненциальное убывание);
- $\alpha_1 < 0$ — *IRF* колеблется (знак чередуется) и затухает.



Импульсный отклик (IRF) для $AR(1)$ с экзогенным регрессором: $\partial y_{t+h} / \partial x_t = \alpha_1^h \cdot \gamma$.

VI.4 Модель ARDL

ARDL (*AutoRegressive Distributed Lags*) — общий вид многомерной модели с лагами как y , так и x . Предполагаем стационарность обоих рядов:

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \gamma_0 x_t + \gamma_1 x_{t-1} + \dots + \gamma_\ell x_{t-\ell} + \varepsilon_t.$$

«Distributed lags» — «распределённые лаги»: эффект x распределён по нескольким периодам через коэффициенты $\gamma_0, \gamma_1, \dots, \gamma_\ell$. ARDL — обобщение и ARIMAX, и обычной авторегрессии.

VI.4.1 Импульсный отклик для ARDL

Считаем влияние x_t на будущие значения y :

$$\frac{\partial y_t}{\partial x_t} = \gamma_0.$$

$$\frac{\partial y_{t+1}}{\partial x_t} = \alpha_1 \cdot \frac{\partial y_t}{\partial x_t} + \gamma_0 \cdot \underbrace{\frac{\partial x_{t+1}}{\partial x_t}}_{=?} + \gamma_1.$$

Вопрос: чему равно $\partial x_{t+1} / \partial x_t$? Если считать x_t независимыми, то нулю. Если же есть динамическая модель для x — нужно учитывать её. Поэтому на практике используют **Bootstrap** (имитационный метод): руками такое не считают.


$$\frac{\partial y_{t+2}}{\partial x_t} = \alpha_1 \cdot \frac{\partial y_{t+1}}{\partial x_t} + \alpha_2 \cdot \frac{\partial y_t}{\partial x_t} + \gamma_0 \frac{\partial x_{t+2}}{\partial x_t} + \gamma_1 \frac{\partial x_{t+1}}{\partial x_t} + \gamma_2.$$

И так далее. В общем виде получается рекуррентная формула, в которой вклад на каждом горизонте складывается из «отголосков» через y и через лаги x .

VI.4.2 IRF и доверительные интервалы

Типичный график IRF для ARDL:

- кривая может иметь немонотонный вид (с горбом и впадиной);
- вокруг неё строят доверительный интервал — он расширяется с ростом h .



Типичный вид IRF для ARDL: немонотонная кривая с расширяющимся с ростом h доверительным интервалом.

Расчёт доверительного интервала: Bootstrap. Аналитически считать дисперсию IRF в ARDL очень сложно, поэтому на практике используют имитационный метод:

1. многократно (~ 100 раз) генерируют псевдо-выборки;
2. на каждой переоценивают модель и считают IRF;
3. по совокупности IRF получают эмпирический доверительный интервал.

Руками такое не считают.



Лекция VII

Векторная авторегрессия (VAR): структурная форма, импульсный отклик, FEVD

VII.1 Векторная авторегрессия

VII.1.1 Приведенная форма

[VAR(p), приведенная форма] Пусть $y_t \in \mathbb{R}^k$ есть вектор из k переменных. Векторная авторегрессия порядка p (p - количество лагов) задается уравнением

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + u_t, \quad \mathbb{E}[u_t u_t'] = \Sigma_u, \quad (1)$$

где y_t и A_0 имеют размер $k \times 1$, каждая матрица коэффициентов $A_1, \dots, A_p$ имеет размер $k \times k$, а $u_t \sim \text{WN}(0, \Sigma_u)$.

Замечание VII.1.1. По форме это обычный авторегрессионный процесс, в котором скаляр y_t заменен на вектор y_t , а скалярные коэффициенты заменены на матрицы A_j . Каждое из k уравнений системы имеет свою константу.

Проклятие размерности. В каждом уравнении VAR справа стоят константа и p лагов всех k переменных, то есть $1 + kp$ коэффициентов. Во всей системе число коэффициентов равно $k(1 + kp)$.

Для $k = 5$ переменных и $p = 3$ лагов в каждом уравнении $1 + 5 \cdot 3 = 16$ коэффициентов. Для $k = 20$ и $p = 4$ уже $1 + 20 \cdot 4 = 81$ коэффициент в каждом из 20 уравнений. Это и есть *проклятие размерности*. Если наблюдений много, базовый VAR оценить можно; но для больших систем обычно применяют байесовские VAR и регуляризацию.

Оценивание и выбор числа лагов. В приведенной форме (1) справа стоят только predetermined лаги, поэтому систему оценивают обычным МНК (поуравнениально) или методом максимального правдоподобия. Порядок p подбирают по информационным критериям AIC или BIC. BIC сильнее штрафует за лишние параметры и выбирает меньшее число лагов, что в условиях большого числа коэффициентов обычно безопаснее.

VII.1.2 Структурная форма и проблема одновременности

Чтобы учесть одновременные взаимные влияния переменных в момент t , записывают структурную форму:

$$B y_t = A_0 + A_1 y_{t-1} + \dots + A_p y_{t-p} + \varepsilon_t, \quad (2)$$

где матрица B кодирует мгновенные связи между компонентами y_t .

Структурную форму нельзя оценить напрямую:

Если y_{2t} входит в уравнение для y_{1t} , а y_{1t} входит в уравнение для y_{2t} , возникает эндогенность из-за одновременности: регрессор коррелирован с ошибкой, и МНК для (2) несостоятелен.

Домножая (2) слева на B^{-1} , получаем приведенную форму (1) с $u_t = B^{-1}\varepsilon_t$. Именно ее и оценивают.

Замечание VII.1.2 (Идентификация). Восстановить структуру из приведенной формы в общем случае нельзя; для этого нужны дополнительные ограничения на B (Холецкий, долгосрочные, знаковые). Этим занимаются структурные VAR (SVAR), что выходит за рамки базового курса.

VII.1.3 Интерпретация: функции импульсного отклика

Почему коэффициенты нечитаемы. Из-за множества лагов одних и тех же переменных возникает сильная мультиколлинеарность: оценки неэффективны, коэффициенты часто незначимы, а лаги одной переменной входят с разными знаками. Поэтому для интерпретации используют не отдельные коэффициенты, а функцию импульсного отклика (IRF).

Импульсный отклик переменной y_i на шок в переменной y_2 на горизонте h :

$$\text{IRF}_{i \leftarrow 2}(h) = \frac{\partial y_{i,t+h}}{\partial \varepsilon_{2t}}. \quad (3)$$

В системе из k переменных получается k^2 откликов.

Представление VMA(∞). Стационарный VAR переписывают в векторное скользящее среднее. Для VAR(1) рекуррентной подстановкой

$$y_t = (I - A_1)^{-1} A_0 + \sum_{j=0}^{\infty} A_1^j \varepsilon_{t-j}. \quad (4)$$

В представлении (4) матрицы A_1^h суть матрицы импульсных откликов: $\partial y_{t+h} / \partial \varepsilon_t' = A_1^h$. Отклик y_i на шок в y_2 на горизонте h есть элемент $(i, 2)$ матрицы A_1^h .

VII.1.4 Декомпозиция дисперсии ошибки прогноза (FEVD)

Ошибка прогноза VAR(1) на горизонте h есть линейная комбинация будущих шоков,

$$y_{t+h} - \hat{y}_{t+h|t} = \sum_{j=0}^{h-1} A_1^j \varepsilon_{t+h-j}. \quad (5)$$

Поскольку структурные шоки некоррелированы, дисперсия ошибки прогноза отдельной переменной раскладывается в сумму вкладов отдельных шоков.

[FEVD] Декомпозиция дисперсии ошибки прогноза показывает, какую долю дисперсии ошибки прогноза переменной y_i на горизонте h обеспечивает каждый структурный шок ε_j . Содержательно: какая переменная на каком горизонте сильнее влияет на вариацию другой.

VII.1.5 Итоги лекции 7

- VAR отвечает на проблему пропущенных переменных: регрессия каждой переменной на лаги всех переменных системы (Симс, 1980).
- Плата за это: проклятие размерности и потеря эффективности, но меньший риск несостоятельности.
- Приведенную форму оценивают по уравнениям; число лагов по AIC или BIC.
- Интерпретация строится на IRF (через $VMA(\infty)$) и FEVD.



Лекция VIII

Коинтеграция: тесты Энгла-Грейнджера и Йохансена, модели ЕСМ и VЕСМ

VIII.1 Коинтеграция

VIII.1.1 Ложные корреляции и идея коинтеграции

Нестационарные ряды опасны тем, что приводят к *ложным корреляциям* (**spurious correlation**): два независимых ряда типа $I(1)$ могут показывать высокую выборочную корреляцию, не имея содержательной связи. Коинтеграция описывает противоположную, содержательную ситуацию, когда нестационарные ряды связаны устойчивым долгосрочным соотношением.

Замечание VIII.1.1. Ряд y_t интегрирован порядка m , то есть $y_t \sim I(m)$, если он становится стационарным после m -кратного дифференцирования: $\Delta^m y_t$ стационарен, а $\Delta^{m-1} y_t$ нет.

[Коинтеграция] Пусть ряды $y_{1t}, \dots, y_{kt}$ каждый порядка $I(m)$. Они называются *коинтегрированными*, если существуют коэффициенты $\beta_1, \dots, \beta_k$ (не все нулевые) такие, что линейная комбинация

$$\sum_{j=1}^k \beta_j y_{jt} \sim I(m'), \quad m' < m. \quad (6)$$

Вектор $(\beta_1, \dots, \beta_k)$ называется коинтегрирующим вектором.

Пусть $x_t, y_t \sim I(1)$. Если некоторая линейная комбинация стационарна,

$$\beta_1 x_t + \beta_2 y_t \sim I(0), \quad (7)$$

то ряды стационарны вместе в этой линейной комбинации. Геометрически каждая траектория x_t и y_t блуждает как $I(1)$, но их разность (например $x_t - y_t$) остается стационарной, то есть ряды не расходятся далеко друг от друга.

Замечание VIII.1.2. Классическая метафора: пьяный матрос и собака на поводке. По отдельности каждый бредет случайным образом (нестационарно, $I(1)$), но расстояние между ними ограничено длиной поводка, поэтому разность их траекторий стационарна. Это и есть коинтеграция.

Замечание VIII.1.3. При наличии коинтеграции модель чисто в разностях теряет информацию о долгосрочном равновесии и оказывается несостоятельной: пропущено коинтеграционное (равновесное) соотношение.

VIII.1.2 Тесты на коинтеграцию

Тест Энгла-Грейнджера

Пусть $y_{1t}, \dots, y_{kt} \sim I(1)$. Процедура состоит из двух шагов.

1. Оценить статическую регрессию в уровнях обычным МНК:

$$\hat{y}_{1t} = \hat{\beta}_0 + \hat{\beta}_2 y_{2t} + \hat{\beta}_3 y_{3t} + \dots + \hat{\beta}_k y_{kt}, \quad (8)$$

и взять остатки $e_t = y_{1t} - \hat{y}_{1t}$.

2. Проверить ряд остатков e_t на стационарность тестом ADF.

Замечание VIII.1.4 (Критические значения). *Так как остатки e_t получены из оцененной регрессии, использовать стандартные критические значения ADF нельзя: применяются специальные критические значения теста Энгла-Грейнджера.*

Если остатки стационарны ($e_t \sim I(0)$), ряды коинтегрированы, а

$$y_{1t} - \hat{\beta}_2 y_{2t} - \dots - \hat{\beta}_k y_{kt} \quad (9)$$

есть оцененное коинтеграционное соотношение. Если остатки нестационарны, коинтеграции нет.

Тест Йохансена

Тест Энгла-Грейнджера ищет не более одного коинтеграционного соотношения. Тест Йохансена умеет отлавливать сразу несколько коинтеграционных соотношений в системе, а также работать с порядками коинтеграции выше первого. Оцененное соотношение вида $y_{1t} = \beta_0 + \beta_2 y_{2t} + \dots$ интерпретируется как долгосрочная (LR) связь между рядами.

VIII.1.3 Модель коррекции ошибок (ЕСМ)

Пусть $x_t, y_t \sim I(1)$ и коинтегрированы. Модель коррекции ошибок (error correction model, ЕСМ) объединяет краткосрочную динамику в разностях с подстройкой к долгосрочному равновесию:

$$\Delta y_t = \underbrace{\alpha_1 \Delta y_{t-1} + \dots + \alpha_p \Delta y_{t-p} + \beta_1 \Delta x_{t-1} + \dots + \beta_k \Delta x_{t-k}}_{\text{краткосрочные эффекты}} + \underbrace{\gamma (y_{t-1} - b_0 - b_1 x_{t-1})}_{\text{коинтегр. соотношение}} + \varepsilon_t. \quad (10)$$

Член в скобках есть отклонение от долгосрочного равновесия в прошлом периоде, а коэффициент γ задает скорость подстройки к равновесию. Для устойчивости подстройки γ должен корректировать отклонение (тянуть ряд назад к равновесию).

[Потребление и доход] Пусть средняя склонность к потреблению равна 90%, тогда долгосрочное (коинтеграционное) соотношение

$$C_t = 0.9 y_t. \quad (11)$$

Пусть предельная склонность к потреблению равна 50%, то есть в краткосрочной динамике $\Delta C_t = 0.5 \Delta y_t$. Тогда ЕСМ записывается как

$$\Delta C_t = 0.5 \Delta y_t - \gamma (C_{t-1} - 0.9 y_{t-1}) + \varepsilon_t, \quad \gamma \in [0, 1]. \quad (12)$$

Смысл: в краткосроке потребление реагирует на изменение дохода с коэффициентом 0.5; если в прошлом периоде потребление превысило свой долгосрочный уровень $0.9 y$, член $-\gamma(\cdot)$ уменьшает текущий прирост, возвращая ряд к равновесию.

VIII.1.4 Векторная модель коррекции ошибок (VECM)

Векторное обобщение ЕСМ для системы коинтегрированных рядов $y_t \sim I(1)$:

$$\Delta y_t = A_0 + A_1 \Delta y_{t-1} + \dots + A_p \Delta y_{t-p} + \gamma (\beta' y_{t-1}) + \varepsilon_t, \quad (13)$$

где $\beta' y_{t-1}$ суть коинтеграционные соотношения, а γ есть матрица скоростей подстройки (нагрузок). Произведение $\Pi = \gamma \beta'$ есть матрица долгосрочного воздействия, и ее ранг равен числу коинтеграционных соотношений (что и оценивает тест Йохансена).

Замечание VIII.1.5. Пропуск имеющейся коинтеграции, то есть оценивание обычного VAR в разностях без члена коррекции ошибок, приводит к несостоятельности. Для коинтегрированных $I(1)$ систем корректной спецификацией служит именно VECM.

VIII.1.5 Итоги лекции 8

- Нестационарные ряды дают ложные корреляции; коинтеграция, наоборот, есть устойчивая долгосрочная связь нестационарных рядов.
- Ряды $I(m)$ коинтегрированы, если их линейная комбинация имеет меньший порядок интегрированности $I(m')$, $m' < m$; в основном случае $I(1)$ ряды дают стационарную ($I(0)$) комбинацию.
- Наличие коинтеграции проверяют тестом Энгла-Грейнджера (через ADF над остатками, со специальными критическими значениями) или тестом Йохансена (несколько соотношений).
- При коинтеграции корректная модель есть ЕСМ (скаляр) или VECM (вектор): краткосрочная динамика в разностях плюс член коррекции ошибок.

