

Эконометрика

Семинар 1:

Модели бинарного выбора (LPM, logit, probit)

Содержание

1	Постановка: модель бинарного выбора	1
2	Подход 1. Линейная вероятностная модель (LPM)	2
3	Подход 2. Logit- и probit-регрессии	2
3.1	Logit-модель	2
3.2	Probit-модель	3
3.3	Оценивание: метод максимального правдоподобия	3
4	Интерпретация коэффициентов	3
4.1	Пример: вероятность завалить метрику	3
5	Предельные эффекты	4
5.1	Пример предельного эффекта	4
6	Отношение шансов (Odds Ratio)	5
6.1	Отношение шансов при изменении признака	5
7	Разбор задачи: модель успеха	5
7.1	Предельный эффект Age	6
8	Домашнее задание: предельный эффект для дамми PhD	6
8.1	Шаг 1. Почему здесь нельзя брать производную	6
8.2	Шаг 2. Линейная часть при двух значениях PhD	7
8.3	Шаг 3. Предельный эффект PhD	7
8.4	Шаг 4. Числовой пример	7

1 Постановка: модель бинарного выбора

Зависимая переменная принимает только два значения:

$$y_i = \begin{cases} 1, & \text{если событие произошло,} \\ 0, & \text{иначе.} \end{cases}$$

Примеры: «студент сдал/не сдал экзамен», «клиент вернул/не вернул кредит», «человек трудоустроен/нет». Обычная линейная регрессия для такой переменной работает плохо — об этом ниже.

Задача — смоделировать вероятность $\mathbb{P}(y_i = 1)$ как функцию признаков $x_1, x_2, \dots$

2 Подход 1. Линейная вероятностная модель (LRM)

Простейшая идея — оценить обычную линейную регрессию:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots$$

и трактовать прогноз как вероятность: $\hat{y} = \hat{\mathbb{P}}(y = 1)$.

LRM — плохая идея. У этого подхода две принципиальные проблемы:

1. **Прогноз выходит за $[0, 1]$:** $\hat{\mathbb{P}}(y = 1) \notin [0, 1]$ — линейная функция неограничена, а вероятность обязана лежать в отрезке.
2. **Встроенная гетероскедастичность:** для бинарной переменной

$$D(y) = \mathbb{P}(1 - \mathbb{P}) = (\beta_0 + \beta_1 x_1 + \dots)(1 - (\dots)),$$

то есть дисперсия зависит от x — это и есть гетероскедастичность.

Дисперсия бинарной (бернуллиевской) величины равна $p(1 - p)$. Так как p зависит от признаков, дисперсия ошибки тоже непостоянна — нарушается предпосылка классической регрессии.

3 Подход 2. Logit- и probit-регрессии

Чтобы вероятность всегда лежала в $[0, 1]$, прогноз «пропускают» через функцию распределения F :

$$\mathbb{P}(y_i = 1) = F(\beta_0 + \beta_1 x_{1i} + \dots).$$

F — функция распределения некоторой случайной величины. Она по определению монотонно растёт от 0 до 1, поэтому результат гарантированно корректная вероятность. Выбор F задаёт тип модели.

Обозначим линейную часть $z = \beta_0 + \beta_1 x_{1i} + \dots$

- **Logit** — F есть функция логистического распределения;
- **Probit** — F есть функция нормального распределения.

3.1 Logit-модель

Логистическая функция:

$$\mathbb{P}(y_i = 1) = \Lambda(z) = \frac{1}{1 + e^{-z}}, \quad z = \beta_0 + \beta_1 x_{1i} + \dots$$

Поведение на границах:

$$z = 0 \Rightarrow \Lambda = \frac{1}{2}, \quad z \rightarrow +\infty \Rightarrow \Lambda \rightarrow 1, \quad z \rightarrow -\infty \Rightarrow \Lambda \rightarrow 0.$$

$\Lambda(z)$ имеет S-образную форму: плавно растёт от 0 до 1, проходя через $\frac{1}{2}$ в нуле. Это функция распределения; её производная $\Lambda'(z)$ — соответствующая плотность (колоколообразная).

3.2 Probit-модель

Здесь F — функция стандартного нормального распределения Φ :

$$\mathbb{P}(y_i = 1) = \Phi(\beta_0 + \beta_1 x_{1i} + \dots), \quad \Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}u^2} du.$$

Logit и probit дают очень похожие результаты — отличается лишь вид «сигмиды». Logit удобнее аналитически (есть формула в явном виде), probit опирается на нормальное распределение.

3.3 Оценивание: метод максимального правдоподобия

Коэффициенты β оцениваются по методу максимального правдоподобия. Функция правдоподобия — произведение вероятностей по всем наблюдениям:

$$\mathcal{L} = \prod_{i: y_i=1} \mathbb{P}(y_i = 1) \cdot \prod_{i: y_i=0} (1 - \mathbb{P}(y_i = 1)) \rightarrow \max_{\beta}.$$

Для logit-модели:

$$\mathcal{L} = \prod_{i: y_i=1} \frac{1}{1 + e^{-z_i}} \cdot \prod_{i: y_i=0} \left(1 - \frac{1}{1 + e^{-z_i}}\right) \rightarrow \max_{\beta} \Rightarrow \hat{\beta}_{ML}.$$

Для каждого наблюдения берётся вероятность именно того исхода, который реально наблюдался: если $y_i = 1$ — вероятность единицы, если $y_i = 0$ — вероятность нуля. Произведение максимизируется по β . Для probit формула такая же, но с Φ вместо Λ .

4 Интерпретация коэффициентов

Важно: в отличие от линейной регрессии, коэффициент β_j сам по себе не равен изменению вероятности — он лишь показывает направление и входит в z нелинейно.

4.1 Пример: вероятность завалить метрику

Пусть оценена logit-модель

$$\hat{\mathbb{P}}(\text{завалить}) = \Lambda(2 - 0,1 \cdot \text{GPA} + 0,3 \cdot \text{Alco}),$$

со стандартными ошибками коэффициентов 0,01 при GPA и 0,02 при Alco.

Проверка значимости. z -статистика — это отношение коэффициента к его стандартной ошибке; сравнивается с критическим значением 1,96:

$$z_{\text{GPA}} = \frac{-0,1}{0,01} = -10, \quad |-10| > 1,96 \Rightarrow \text{значим},$$

$$z_{\text{Alco}} = \frac{0,3}{0,02} = 15, \quad |15| > 1,96 \Rightarrow \text{значим}.$$

Прогноз вероятности. При GPA = 5, Alco = 2:

$$z = 2 - 0,1 \cdot 5 + 0,3 \cdot 2 = 2,1,$$

$$\hat{\mathbb{P}}(\text{завалить}) = \Lambda(2,1) = \frac{1}{1 + e^{-2,1}} \approx 0,89.$$

При GPA = 6 (так что $z = 2$):

$$\hat{\mathbb{P}} = \Lambda(2) = \frac{1}{1 + e^{-2}} \approx 0,88.$$

Видно, что один и тот же прирост GPA меняет вероятность по-разному в зависимости от исходного уровня — это и есть нелинейность logit-модели. Поэтому вводят понятие предельного эффекта.

5 Предельные эффекты

Предельный эффект (marginal effect) показывает, как меняется вероятность при изменении признака. Для непрерывной переменной это частная производная:

$$ME_{x_j} = \frac{\partial \mathbb{P}(y_i = 1)}{\partial x_j} = \beta_j \cdot \Lambda'(\beta_0 + \beta_1 x_{1i} + \dots).$$

Производная логистической функции:

$$\Lambda'(z) = \left(\frac{1}{1 + e^{-z}} \right)' = \frac{e^{-z}}{(1 + e^{-z})^2} = \Lambda(z) (1 - \Lambda(z)).$$

Предельный эффект — это коэффициент β_j , умноженный на плотность $\Lambda'(z)$. Поскольку плотность зависит от z (то есть от значений всех признаков), предельный эффект не постоянен — его считают в конкретной точке.

5.1 Пример предельного эффекта

Для модели из предыдущего раздела предельный эффект GPA:

$$ME_{\text{GPA}} = -0,1 \cdot \Lambda'(2 - 0,1 \cdot \text{GPA} + 0,3 \cdot \text{Alco}).$$

В точке GPA = 5, Alco = 2 (то есть $z = 2,1$):

$$ME_{\text{GPA}} = -0,1 \cdot \Lambda'(2,1).$$

6 Отношение шансов (Odds Ratio)

Шансы (odds) — отношение вероятности успеха к вероятности неудачи:

$$\text{Odds}_i = \frac{\mathbb{P}(y_i = 1)}{\mathbb{P}(y_i = 0)} = \frac{\frac{1}{1 + e^{-z}}}{1 - \frac{1}{1 + e^{-z}}}.$$

Упрощаем. Знаменатель: $1 - \frac{1}{1 + e^{-z}} = \frac{e^{-z}}{1 + e^{-z}}$, поэтому

$$\text{Odds}_i = \frac{1/(1 + e^{-z})}{e^{-z}/(1 + e^{-z})} = \frac{1}{e^{-z}} = e^z = e^{\beta_0 + \beta_1 x_{1i} + \dots}$$

Красивое свойство logit-модели: шансы — это просто экспонента от линейной части. Логарифм шансов линеен по признакам, поэтому logit ещё называют моделью «лог-шансов».

6.1 Отношение шансов при изменении признака

Увеличим признак x_k на единицу, остальные оставим без изменения:

$$x_{ij}^* = x_{ij} \quad \forall j \neq k, \quad x_{ik}^* = x_{ik} + 1.$$

Тогда новые шансы:

$$\text{Odds}_i(x_i^*) = e^{\beta_0 + \beta_1 x_{1i} + \dots + \beta_k(x_{ik} + 1) + \dots}$$

Отношение шансов (Odds Ratio):

$$OR = \frac{\text{Odds}_i(x_i^*)}{\text{Odds}_i(x_i)} = \frac{e^{\dots + \beta_k(x_{ik} + 1) + \dots}}{e^{\dots + \beta_k x_{ik} + \dots}} = e^{\beta_k}.$$

Интерпретация коэффициента через OR:

$$OR_k = e^{\beta_k}, \quad \beta_k = \ln(OR_k).$$

При увеличении признака x_k на единицу шансы умножаются на e^{β_k} . Это удобный способ содержательно объяснить коэффициенты logit-модели.

7 Разбор задачи: модель успеха

Оценена logit-модель $\widehat{\mathbb{P}}(\text{Success}_i) = \Lambda(z)$ с линейной частью

$$z = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - 5 \text{ PhD} - 1 \text{ Exp} + 0,2 \text{ Exp} \cdot \text{ PhD}.$$

Результаты оценивания:

Переменная	$\hat{\beta}$	$\widehat{s.e.}$	z	Значимость
const	1,5	0,1	15	значим
Age	2	0,4	5	значим
Age ²	-0,02	0,3	0,06	не значим
PhD	-5	1,2	4,16	значим
Exp	-1	3	0,3	не значим
Exp·PhD	0,2	0,001	200	значим

z -статистика каждого коэффициента — это $\hat{\beta}/\widehat{s.e.}$. Значимы те, у кого $|z| > 1,96$: const, Age, PhD, Exp·PhD. Незначимы Age² ($z = 0,06$) и Exp ($z = 0,3$).

7.1 Предельный эффект Age

Age — непрерывная переменная, поэтому берём производную. В z она входит дважды (как Age и как Age²):

$$\frac{\partial z}{\partial \text{Age}} = 2 - 2 \cdot 0,02 \text{ Age} = 2 - 0,04 \text{ Age}.$$

Предельный эффект:

$$ME_{\text{Age}} = (2 - 0,04 \text{ Age}) \cdot \Lambda'(z) = (2 - 0,04 \text{ Age}) \cdot \frac{e^z}{(1 + e^z)^2}.$$

Множитель $(2 - 0,04 \text{ Age})$ — производная линейной части по Age. Второй множитель — плотность логистического распределения. Эффект зависит и от самого возраста, и от значений остальных признаков через z .

8 Домашнее задание: предельный эффект для дамми PhD

Задано на дом. В конце семинара осталась задача: найти предельный эффект для переменной **PhD** в модели

$$\widehat{\mathbb{P}}(\text{Success}) = \Lambda(z), \quad z = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - 5 \text{ PhD} - \text{Exp} + 0,2 \text{ Exp} \cdot \text{PhD}.$$

8.1 Шаг 1. Почему здесь нельзя брать производную

PhD — **дамми-переменная**: она принимает только два значения, 0 или 1 (есть степень / нет степени). Производная по ней не имеет смысла — переменная не изменяется непрерывно.

Для непрерывной переменной (как Age) предельный эффект — это производная. Для дискретной (дамми) предельный эффект определяют как разность вероятностей при двух её значениях.

Поэтому предельный эффект дамми-переменной считается как

$$ME_{\text{PhD}} = \mathbb{P}(\text{Success} \mid \text{PhD} = 1) - \mathbb{P}(\text{Success} \mid \text{PhD} = 0).$$

8.2 Шаг 2. Линейная часть при двух значениях PhD

Подставим $\text{PhD} = 1$. Важно: PhD входит в z дважды — напрямую (-5 PhD) и во взаимодействии ($0,2 \text{ Expr} \cdot \text{PhD}$). Меняются *оба* члена:

$$z_1 = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - 5 \cdot 1 - \text{Expr} + 0,2 \text{ Expr} \cdot 1.$$

$$z_1 = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - 5 - 0,8 \text{ Expr}.$$

Подставим $\text{PhD} = 0$ — члены с PhD обнуляются:

$$z_0 = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - \text{Expr}.$$

При $\text{PhD} = 1$ член $-\text{Expr} + 0,2 \text{ Expr}$ даёт $-0,8 \text{ Expr}$. При $\text{PhD} = 0$ остаётся только $-\text{Expr}$. Из-за взаимодействия эффект PhD зависит от стажа Expr — это надо учитывать.

8.3 Шаг 3. Предельный эффект PhD

$$ME_{\text{PhD}} = \Lambda(z_1) - \Lambda(z_0) = \frac{1}{1 + e^{-z_1}} - \frac{1}{1 + e^{-z_0}}$$

где

$$z_1 = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - 5 - 0,8 \text{ Expr}, \quad z_0 = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - \text{Expr}.$$

8.4 Шаг 4. Числовой пример

Посчитаем эффект в конкретной точке, например $\text{Age} = 10$, $\text{Expr} = 3$.

При $\text{PhD} = 1$:

$$z_1 = 1,5 + 2 \cdot 10 - 0,02 \cdot 100 - 5 - 0,8 \cdot 3 = 1,5 + 20 - 2 - 5 - 2,4 = 12,1.$$

$$\Lambda(z_1) = \frac{1}{1 + e^{-12,1}} \approx 1,000.$$

При $\text{PhD} = 0$:

$$z_0 = 1,5 + 2 \cdot 10 - 0,02 \cdot 100 - 3 = 1,5 + 20 - 2 - 3 = 16,5.$$

$$\Lambda(z_0) = \frac{1}{1 + e^{-16,5}} \approx 1,000.$$

Предельный эффект:

$$ME_{\text{PhD}} = \Lambda(12,1) - \Lambda(16,5) \approx 0.$$

Итог домашнего задания.

$$ME_{\text{PhD}} = \Lambda(z_1) - \Lambda(z_0),$$

$$z_1 = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - 5 - 0,8 \text{ Expr}, \quad z_0 = 1,5 + 2 \text{ Age} - 0,02 \text{ Age}^2 - \text{Expr}.$$

Главное: для дамми-переменной предельный эффект — это *разность* вероятностей, а не производная. При наличии взаимодействия $\text{Expr} \cdot \text{PhD}$ при переключе-

чении PhD меняется и член взаимодействия, поэтому эффект PhD зависит от стажа Exp .

В выбранной точке ($Age = 10$, $Exp = 3$) обе вероятности близки к единице, поэтому $ME_{PhD} \approx 0$ — конкретное числовое значение зависит от точки, в которой считается эффект.

